LLM 竞品分析

一、案例背景

1.1 项目背景

如今大模型逐渐深入地参与并影响人们的生活、工作与经济，同时使用的人与企业也在逐渐增多。但是一部分人与个别企业不太了解不同大语言模型适配场景、能力边界、未来发展态势与把握发展机会。基于此，想对市面上常用的几个大模型的能力进行竞品分析。

1.2 分析目标

1、梳理主流大语言模型能力的功能现状
2、识别大语言模型的发展趋势
3、输出公司与个人使用建议

1.3 选择竞品

竞品	类型
Deepseek	国内强编程类模型
豆包	国内综合能力模型
GPT	国外综合能力模型
Claude Opus	国外强编程类模型
Gemini	国外综合能力模型

包含国内外对比，综合与编程对比。

二、AI 辅助竞品分析步骤

定义框架（评判标准）→采集信息（支撑依据）→矩阵对比（明了结果）→输出洞察建议（结论）

每一步的目的与 AI 扮演的角色，如下表所示：

步骤	目的	人的角色	AI 的角色
定义框架	确定不同维度与指标的评判标准	审核与修改框架	构建框架
采集信息	作为评判标准的支撑	引导搜索与校验信息	搜索与整理信息
矩阵对比	更明了地对比各维度	判断与取舍	生成矩阵
输出洞察与意见	给出有价值的结论	判断与验证	生成结论与建议

三、竞品分析过程

3.1 定义框架

我输入的 Prompt：

角色：

假如你是一个资深的竞品分析专家，特别擅长做产品分析，同时对 AI 与 LLM 非常精通。

总体要求：

需要对不同类型 LLM 做竞品分析。

分析目标：

1、梳理主流大语言模型能力的功能现状

2、识别大语言模型的发展趋势

3、输出公司与个人使用建议

竞品对象：

Deepseek、豆包、GPT、Claude Opus、Gemini

具体要求：

请你帮我设计一个结构化竞品分析框架，具体要求

1、明确分析维度（至少应包含对话、编程、工作、用户评价）；

2、每个维度勒出不同的指标；

3、针对每个指标制定对应的评分标准（1-5 分）；

4、用表格的形式输出。

限制：

定义的框架要为 “公司与个人使用建议”输出，不是泛泛而谈。

3.1.1AI 的输出：

LLM 竞品分析框架设计

以下框架围绕**"公司与个人使用建议"**这一最终输出目标设计，每个指标的评分标准都锚定实际使用决策，而非泛泛的技术参数。

一、分析维度总览

表格

维度	核心问题	对使用建议的意义
对话能力	日常交互是否够用、可靠	决定能否作为主力助手
编程能力	代码场景能否提效	决定开发者选型优先级
工作能力	办公 / 专业场景能否落地	决定企业采购与岗位适配
用户评价	真实体验与口碑	决定长期使用意愿与风险
成本与性价比	投入产出比是否合理	决定个人付费与企业预算
企业级能力	安全、合规、可控性	决定公司能否规模化部署

二、各维度指标与评分标准（1-5 分）

维度 1：对话能力

表格

指标	1 分	3 分	5 分	决策含义
自然语言理解	经常误解意图，需反复澄清	常规问题理解准确，复杂表述偶有偏差	准确理解模糊、口语化、含歧义指令	5 分可独立处理 仅适合简单问答
多轮上下文记忆	3 轮内丢失关键信息	8-10 轮保持一致，长对话偶有遗忘	20 轮以上稳定记忆，能跨话题关联	长对话工作流必
推理与逻辑	简单推理即出错	常规逻辑链正确，复杂推理需引导	多步推理、因果分析、反事实推理稳定	分析类任务核心
长文本处理	超 8K 即质量骤降	32K 内可用，超长文本摘要有遗漏	128K + 精准检索、总结、对比	文档 / 合同场景
中文表达质量	翻译腔明显、用词生硬	表达自然，专业术语偶有不当	地道中文，适配公文 / 文案 / 学术等语体	中文场景选型第

维度 2：编程能力

表格

指标	1 分	3 分	5 分	决策含义
代码生成准确率	生成代码需大量修改才能运行	常规功能一次可用，复杂逻辑需调试	复杂业务逻辑一次通过率高	直接决定提
代码调试与排错	无法定位 bug，给出错误建议	能定位常见错误，复杂 bug 需人工介入	能复现、定位、修复复杂 bug 并解释根因	调试场景核
多语言与框架覆盖	仅支持主流语言，框架知识陈旧	覆盖 10 + 语言，主流框架知识较新	覆盖冷门语言 / 框架，知识更新及时	技术栈匹配
大型项目理解	仅能处理单文件	能理解多文件模块关系	能跨文件重构、架构建议、代码审查	企业级开发
代码解释与教学	解释含糊或错误	能解释常规代码逻辑	能深入浅出讲解复杂算法与设计模式	学习 / Cod

维度 3：工作能力

表格

指标	1 分	3 分	5 分	决策含义
文档生成与处理	格式混乱，内容需重写	常规文档可用，格式基本规范	长文档结构清晰、格式精准、可直接交付	办公场景核心指
数据分析能力	无法处理数据，公式错误多	能做基础统计与可视化，复杂分析需指导	能独立完成清洗、建模、解读、报告	数据岗选型关键
任务规划与执行	无法拆解复杂任务	能拆解任务，但步骤需人工调整	能自主规划、分步执行、动态修正	Agent / 自动化
专业领域知识	专业问题频繁幻觉	主流领域知识可靠，深度问题有限	法律 / 医疗 / 金融等深度领域可信赖	专业岗选型决定
工具调用与集成	不支持或调用频繁失败	能调用基础工具，偶有参数错误	稳定调用多工具、链式执行、错误自愈	工作流集成关键

维度 4：用户评价

表格

指标	1 分	3 分	5 分	决策含义
响应速度	经常超时（>30s）	常规响应 3-8s，复杂任务稍慢	首字 < 1s，复杂任务也在合理时间	日常体验底线指
服务稳定性	频繁宕机 / 限流	偶有不可用，高峰期有限流	99.9% 可用，无感知限流	企业生产环境硬
界面与交互体验	难用，功能缺失	基础功能完善，体验中规中矩	交互流畅，细节打磨到位，多端同步	个人长期使用意
社区与生态	无社区，插件 / 模板匮乏	有基础社区，第三方工具可用	活跃社区，丰富插件 / 模板 / 最佳实践	学习成本与扩展
用户口碑与推荐度	差评集中，用户流失率高	评价两极，有明确适用场景	高满意度，用户主动推荐	综合体验的结果

维度 5：成本与性价比

表格

指标	1 分	3 分	5 分	决策含义
免费额度 / 入门门槛	无免费额度，试用成本高	有免费额度但限制明显	generous 免费额度，低门槛试用	个人用户入门
单位使用成本	同能力下价格显著高于竞品	价格中等，与能力基本匹配	同能力下价格最优或物超所值	规模化使用核
计费透明度	计费规则复杂，账单难预测	规则清晰，偶有意外费用	完全透明，有预算控制与告警	企业预算管理
增值服务价值	增值服务鸡肋	部分增值服务有用	增值服务显著提升效率，值得付费	付费版升级决

维度 6：企业级能力

表格

指标	1 分	3 分	5 分	决策含义
数据安全与隐私	数据用于训练，无隐私保障	有隐私协议，数据不默认用于训练	零数据留存，通过安全认证（SOC2 等）	企业采购一票
合规与可审计	无合规能力	基础合规，日志有限	完整审计日志、内容过滤、合规报告	金融 / 政务 /
私有化 / 定制部署	仅公有云	支持专有云 / 专属实例	支持本地私有化部署与模型微调	数据敏感企业
团队管理与权限	无团队功能	基础团队空间，权限粗放	细粒度权限、SSO、用量统计、审批流	中大型企业管
API 与系统集成	API 不稳定，文档差	API 可用，文档基本完善	API 稳定高性能，丰富 SDK 与最佳实践	系统集成可行

三、评分权重与使用建议输出逻辑

框架不是为了打分而打分，**评分直接映射到使用建议**：

权重分配（按使用场景差异化）

表格

场景	对话	编程	工作	用户评价	成本	企业级
个人日常助手	30%	10%	20%	20%	20%	0%
个人开发者	15%	40%	15%	15%	15%	0%
中小企业办公	15%	15%	30%	15%	15%	10%
大型企业部署	10%	15%	25%	10%	10%	30%
专业领域（法律 / 医疗）	15%	5%	35%	10%	10%	25%

建议输出规则

1. **个人推荐**：综合得分前 2 名 + 按场景（日常 / 编程 / 学习）给出首选与备选
2. **公司推荐**：企业级维度≥4 分是入围门槛，再按工作能力与成本排序
3. **混合策略建议**：不同场景用不同模型（如编程用 A、文档用 B、敏感数据用私有化 C）
4. **风险提示**：任一维度≤2 分必须标注风险，不建议在该场景使用

3.1.2 我做出的调整

1、本地部署储存大小——从企业角度考虑为了减少泄密风险与节约成本，部署本地模型在所难免。

2、模型调用与微调难度——随着 AI 的发展，部分企业的部分工作肯定会需要自己的大模型，考虑成本与时间大概率会选择对已有模型进行微调。

3.2 批量信息采集

3.2.1 我的 Prompt

分别要对 Deepseek、豆包、GPT、Claude Opus、Gemini，这 5 个 LLM 分析。先分析 deepseek，其他 LLM 也按照以下结构进行提问。

3.2.1.1 deepseek 信息收集

要求：

请帮我分析 Deepseek 能力与功能现状。

信息来源：

1、deepseek 官网产品介绍页；

2、deepseek 帮助中心文档；

3、公开产品测评文章。

请按照一下框架提取信息：

【对话能力】
自然语言理解
多轮上下文记忆
推理与逻辑
长文本处理
中文表达质量

【编程能力】
代码生成准确率
代码调试与排错
多语言与框架覆盖
大型项目理解
代码解释与教学

【工作能力】
文档生成与处理
数据分析能力
任务规划与执行
专业领域知识
工具调用与集成

【用户评价】
响应速度
服务稳定性
界面与交互体验
社区与生态
用户口碑与推荐度

【成本与性价比】
免费额度 / 入门门槛
单位使用成本
计费透明度
增值服务价值

【企业级能力】
数据安全与隐私
合规与可审计
私有化 / 定制部署
团队管理与权限
API 与系统集成

限制：请用事实描述，不要主观评价。如果出现了信息不确定，就标注待确认。一定要保证信息的真实性。

AI 的回答：

DeepSeek 能力与功能现状（事实提取）

> 信息来源：DeepSeek 官网及 API 文档、帮助中心、公开测评文章。信息截止时间：2026 年 9 月。标注「待确认」表示未在可靠来源中找到明确事实依据。

一、对话能力

表格

指标	事实描述	来源
自然语言理解	当前主力模型为 DeepSeek-V4 系列（V4-Pro / V4-Flash），2026 年 4 月发布预览版、8 月发布正式版。V4-Pro 总参数 1.6 万亿、激活参数 490 亿；V4-Flash 总参数 2840 亿、激活参数 130 亿。官方称 V4-Pro "性能比肩顶级闭源模型"。V3.2 在公开推理类 Benchmark 中达到 GPT-5 水平，仅略低于 Gemini-3.0-Pro。	官网 API 文档、CSDN
多轮上下文记忆	V4 系列上下文窗口为 **1M tokens**（1048565 tokens），最大输出长度 **384K tokens**。支持外部记忆系统集成（短期对话缓冲、长期数据库 / 向量嵌入）。推理模型（deepseek-reasoner）最大支持 64K 上下文，推理内容不计入 64K。	API 文档、腾讯云文档
推理与逻辑	采用混合推理架构，一个模型同时支持**思考模式与非思考模式**（可通过 `enable_thinking` 参数切换）。R1 系列为推理专用模型，在 AIME 2025 测试中准确率由旧版 70% 提升（具体新版数值待确认）。V3.1 被官方称为 "迈向 Agent 时代的第一步"。	官网 API 文档、抖音百科
长文本处理	V4 系列支持 1M tokens 上下文。V3.2-Exp 采用稀疏注意力机制（DSA），将长文本处理复杂度从 O (n^2) 降至 O (nlogn)。支持流式输出和基于分块的推理（chunk-based reasoning）。支持 Context Caching on Disk 磁盘上下文缓存技术，以 64 token 为存储单元，未使用缓存条目数小时至数天内自动清除。	API 文档、CSDN 测评
中文表达质量	由中国公司深度求索开发，训练数据包含大量中文语料，中文为原生优化语言。官方产品界面、文档均以中文为主。具体表达质量的量化测评数据待确认。	公开信息

二、编程能力

表格

指标	事实描述	来源
代码生成准确率	DeepSeek-V3.1-Thinking 在 Aider 编码测试中取得 **76.3%**，超过 Claude 4 Opus、Gemini 2.5 Pro (0325)。V3.1 非思考模式在 Aider 中取得 71.6%，在开源模型中排名第一。R1-0528 在 LMArena 编程测试中排名第 2。V4-Pro 在 Agentic Coding 评测中达到当前开源模型最佳水平。	36 氪、太平洋科技、InfoQ、官网 API 文档
代码调试与排错	R1 系列在 LiveCodeBench 和 SWE Verified 等编码基准测试中得分提升，与 OpenAI o1 差距缩小。arXiv 论文指出：在工程导向编码任务中，OpenAI-o1-1217 在 Aider 上优于 DeepSeek-R1，但在 SWE Verified 上表现相当。具体调试能力的独立测评数据待确认。	arXiv、掘金
多语言与框架覆盖	官网称支持多种编程语言（具体数量待确认，第三方页面称 "0 + 支持编程语言" 数据不可靠）。API 支持 FIM（Fill-in-the-Middle）代码补全（仅非思考模式）。覆盖 Python、Java、C++、JavaScript、Go 等主流语言（来自测评描述，非官方完整清单）。	官网、OpenClaw 测评
大型项目理解	V4-Pro Agent 能力大幅增强，在 Agentic Coding 评测中表现优异。支持多文件读取、代码重构等 Agent 场景（通过第三方工具如 DeepSeek Engineer 实现）。模型本身是否原生支持大型项目级理解的官方说明待确认。	官网 API 文档、GitHub
代码解释与教学	支持代码解释功能（用户可上传代码文件要求解释）。深度思考模式下可分步展示推理过程，适用于代码教学场景。具体代码解释质量的量化数据待确认。	产品使用手册、公开测评

三、工作能力

表格

指标	事实描述	来源
文档生成与处理	网页端支持上传 **PDF、Word、Excel、PPT、TXT、Markdown、图片、代码文件、CSV** 等格式。可对文档进行摘要、分析、翻译、问答操作。支持拖拽上传。可直接对文档内容提问，AI 自动定位关键信息并生成结构化回答。	官网功能页、使用指南
数据分析能力	支持上传 CSV、Excel 文件进行内容分析、数据统计、信息提取。是否提供原生代码解释器（Code Interpreter）用于运行 Python 数据分析：**待确认**（搜索结果中未找到官方明确说明）。	功能介绍页
任务规划与执行	V4 系列 Agent 能力大幅提升，官方称 "在生产环境中的性能表现提升尤为显著"。V3.1 支持多种 Code Agent 框架。API 支持 Function Calling（最多传入 128 个 function），兼容 OpenAI API 格式。支持 Responses API。	官网 API 文档、36 氪
专业领域知识	模型训练覆盖通用知识。R1 系列在数学、金融分析等专业推理场景优化。是否有针对法律、医疗等特定专业领域的专门模型或微调版本：**待确认**（搜索结果未找到官方专业领域模型清单）。	腾讯云、公开信息
工具调用与集成	API 支持 **Function Calling / Tool Calls**（最多 128 个工具），兼容 OpenAI 格式。支持 **JSON Output**（通过 `response_format: json_object`）。支持 **Anthropic 兼容接口**。支持对话前缀续写（Beta）、FIM 补全（Beta）。支持 Responses API。并发限制：V4-Flash 2500，V4-Pro 500。	API 文档、官网价格页

四、用户评价

表格

指标	事实描述	来源
响应速度	V3 版本推理加速 40%，生成吐字速度从 20 TPS 提升至 60 TPS（相比 V2.5 提升 3 倍）。日常简单问题通常 1-2 秒内给出答案；复杂任务（如 2000 字报告）官方 App 一般 10-15 秒内开始逐步输出。R1 思考模式响应较慢，"要等几分钟"（来自用户对比描述）。	CSDN 测评、发现 AI、CSDN 对比
服务稳定性	多个来源反馈高峰期频繁出现 **"服务器繁忙"、502 错误、响应超时。**2025 年 1 月因用户激增曾临时关闭注册。学术研究（TechRxiv）指出用户反馈 "间歇性技术稳定性" 问题。应用商店评分从 4.2 降至 3.98（第三方站点数据，具体平台待确认）。API 服务通过峰谷计价引导流量分流。	OpenClaw、productivity-apps、TechRxiv、界面新闻
界面与交互体验	提供网页端（chat.deepseek.com）和移动 App。网页端对话框有三个功能开关：**深度思考 (R1)、联网搜索、附件上传。**界面风格简洁。学术研究中 UI/UX 主题得分为 0.60（中等积极），用户反馈存在注册 / 登录问题、偶尔 UI bug、语音输入需求等。	使用教程、TechRxiv
社区与生态	模型开源（V4 系列权重开放），GitHub 社区活跃。Reddit r/DeepSeek 社区活跃，V4 发布后相关帖子获 177 票、98% 好评。支持多种第三方 Agent 框架。有丰富的第三方教程、最佳实践。官方是否提供官方插件市场或模板中心：**待确认。**	掘金、GitHub
用户口碑与推荐度	V4 发布后社区评价正面，"性能与价格的双重冲击"。核心痛点集中在高峰期稳定性。免费策略获得大量用户认可。LMArena Text Arena 中 DeepSeek 能与 GPT-4o、Claude Opus 直接竞争。	掘金、InfoQ、SearchTools.ai

五、成本与性价比

表格

指标	事实描述	来源
免费额度 / 入门门槛	网页端（chat.deepseek.com）和官方 App **完全免费**，无使用次数限制，搭载 V4-Pro 旗舰模型，支持联网搜索、深度思考、文件上传。API 新用户是否有免费额度：**待确认**（搜索结果未找到当前免费额度政策）。	官网功能页
单位使用成本	API 采用**峰谷分时计价**（2026 年 8 月 17 日起生效），单位：元 / 百万 tokens： ・V4-Flash：输入 (缓存未命中) 1.5 (空闲)/3.0 (高峰)，输出 4.5/9.0 ・V4-Pro：输入 (缓存未命中) 4.5/9.0，输出 13.5/27.0 ・缓存命中输入极低价：Flash 0.05/0.10，Pro 0.15/0.30 高峰时段：周一至周五 9:00-12:00、14:00-18:00（北京时间），空闲时段价格为高峰的 50%。	官网价格页、新浪财经、界面新闻
计费透明度	计费基于 token 消耗量 × 单价，从充值余额或赠送余额扣减，优先扣减赠送余额。官网提供明确的价格表和峰谷时段定义。支持 Context Caching 缓存命中低价计费。API 返回 usage 字段（prompt_tokens、completion_tokens、total_tokens）。是否提供预算控制与用量告警功能：**待确认。**	官网价格页、API 文档
增值服务价值	提供磁盘上下文缓存（Context Caching on Disk）降低重复输入成本。提供 Anthropic 兼容接口、Responses API 等开发者功能。是否有付费 Pro 会员、企业支持 SLA、专属实例等增值服务：**待确认**（搜索结果未找到官方增值服务清单）。	API 文档

六、企业级能力

表格

指标	事实描述	来源
数据安全与隐私	旗舰模型以**开放权重**形式发布，可下载在自有基础设施运行。官方托管产品运行在**中国大陆境内**。私有化部署方案支持数据零外流（所有数据仅在内网流转）。API 服务的数据是否用于训练：**待确认**（未找到官方明确声明）。	Brocent、freedeepseekapi
合规与可审计	私有化部署需遵循《生成式人工智能服务管理暂行办法》《网络安全法》《数据安全法》《个人信息保护法》。私有化方案可实现全链路审计日志（含 traceID、tenantID，7 年以上存档）、敏感字段实时监测、响应内容自动审计。官方 SaaS 服务是否提供审计日志功能：**待确认**。	CSDN 合规分析
私有化 / 定制部署	支持完全私有化部署，运行环境为企业自有数据中心或私有云，网络物理 / 逻辑隔离。硬件要求：NVIDIA A100/H100 GPU 集群（本地部署显卡 VRAM 至少 24G 起步）。已完成**昆仑、壁仞、昇腾、天数智芯**等国产芯片适配。支持模型微调。第三方（如数据宝）提供基于 DeepSeek 的企业版解决方案。	freedeepseekapi、数据宝、CSDN
团队管理与权限	官方是否提供原生团队管理后台、SSO、细粒度权限、用量统计：**待确认**（搜索结果未找到官方团队管理功能说明）。第三方平台（如火山引擎 veStack、OpenClaw）提供企业级安全合规、统一管理与运维、权限管控与行为审计等能力。	火山引擎、CSDN
API 与系统集成	提供 OpenAI 兼容格式 API（BASE URL: https://api.deepseek.com）和 Anthropic 兼容格式。支持 Function Calling、JSON Output、Responses API、FIM、对话前缀续写。并发限制：Flash 2500、Pro 500。SDK 支持：Python、Node.js 等（通过 OpenAI 兼容 SDK 调用）。是否提供官方各语言原生 SDK：**待确认**。	官网价格页、API 文档

七、待确认事项汇总

以下信息在本次检索中未找到可靠来源，如需完整分析建议进一步核实：

1. 官方代码解释器（Code Interpreter）是否存在
2. 法律 / 医疗等专业领域专用模型
3. API 新用户免费额度政策
4. 预算控制与用量告警功能
5. 付费 Pro 会员 / 企业 SLA / 专属实例
6. 官方 SaaS 服务数据是否用于训练
7. 官方 SaaS 审计日志功能
8. 官方原生团队管理后台（SSO、权限、用量统计）
9. 官方各语言原生 SDK 清单
10. 中文表达质量的量化测评数据
11. 代码调试能力的独立量化测评
12. 支持编程语言的官方完整清单

3.2.1.2 豆包信息收集

豆包（Doubao）能力与功能现状（事实提取）

> 信息来源：豆包官网、火山引擎产品页与文档、帮助中心、公开测评文章。信息截止时间：2026 年 9 月。标注「待确认」表示未在可靠来源中找到明确事实依据或来源存在矛盾。

一、对话能力

表格

指标	事实描述	来源
自然语言理解	当前主力模型为 Doubao-Seed-2.1 系列（2026 年 6 月 23 日发布），包含 Pro（旗舰深度推理）、Turbo（量产性价比）、Evolving（快速迭代）三个版本。2.0 系列（2026 年 2 月 14 日发布）包含 Pro、Lite、Mini、Code 四款。火山引擎官网称日均 Token 使用量达 **180 万亿**。第三方数据称日活跃用户 1.45 亿、月活 4.2 亿（具体统计口径待确认）。	火山引擎官网、抖音百科、深度指南
多轮上下文记忆	Seed-2.1 系列（Pro/Turbo/Evolving）上下文窗口为 **256K tokens**，最大输入 256K，最大回答 256K（默认 4K），最大思维链 256K。2.0 Lite/Mini/Pro 上下文窗口 256K，最大输入 224K，最大回答 128K。角色扮演模型上下文 128K。系统提示词称 "支持多轮总和最多 20 万字的输入和输出"（与 256K token 口径不同，可能为 C 端产品限制）。	火山引擎模型列表、飞书文档
推理与逻辑	支持**深度思考模式**，通过 `thinking` 参数控制，默认开启 medium 模式，支持 **minimal / low / medium / high** 四种思考长度调节。2025 年 3 月升级 "深度思考" 支持**边想边搜**，思考过程中可基于推理多次调用工具、搜索信息。豆包大模型 1.6 在 GPQA Diamond 达 81.5 分（来自第三方页面，非最新模型数据）。	火山引擎文档、3DM 更新日志
长文本处理	上下文窗口 256K tokens。网页端文档处理上限 **100 万字**。支持上传 PDF、Word、Excel 等文件进行长文档解析，自动生成摘要、思维导图，精准定位关键段落。支持 AI 阅读功能，可智能调节页面宽度。	豆包官网功能页、极速下载更新日志
中文表达质量	由字节跳动自研，训练数据包含大量中文语料，中文为原生优化语言。产品界面、文档均以中文为主。测评描述称 "中文需求理解精准，口语化中文描述也能生成可用代码"（来自测评文章，非量化数据）。具体表达质量的独立量化测评数据待确认。	CSDN 测评

二、编程能力

表格

指标	事实描述	来源
代码生成准确率	Doubao-Seed-Code（2025 年 11 月发布）为国内首个原生支持视觉理解的代码大模型，在 **SWE-bench Verified 榜单中 78.8%**，刷新国内 SOTA。Seed 2.1 Pro 在 **Terminal Bench 2.1 得 71.0**（Claude Opus 4.7 为 71.7），**SciCode 59.8**（超 GPT-5.5 的 58.4 和 Opus 4.7 的 56.4），**NL2Repo 47.0**（超 GPT-5.5 的 45.0）。在 ProgramBench 基准上具备从零完成系统级工程的能力。	CSDN 测评、量子位、51CTO、字节跳动 Seed 博客
代码调试与排错	官网称代码助手支持代码调试和优化。Seed 2.1 Pro 可连续运行近 18 小时、经历 9 轮迭代完成芯片设计 RTL 代码，并跑通仿真、测试、综合检查等完整工程流程。具体调试能力的独立量化测评数据待确认。	量子位、36 氪、豆包官网
多语言与框架覆盖	官网称支持 **16 + 编程语言**的代码生成、调试和优化。自由画布可预览代码效果，数据处理和可视化一键完成。具体支持语言清单待确认。	豆包官网功能页
大型项目理解	Seed 2.1 Pro 在 NL2Repo-Bench 基准上表现良好，可独立完成软件系统的架构设计与代码实现。芯片设计 Demo 完成 6 个核心模块、1303 行 RTL 代码。2.0 系列最大输入 224K，可支持项目级代码理解。是否原生支持多文件批量上传与跨文件重构：待确认。	字节跳动 Seed 博客、量子位
代码解释与教学	支持代码解释功能（上传代码文件可要求解释）。深度思考模式下可分步展示推理过程。具体代码解释质量的量化数据待确认。	产品功能介绍

三、工作能力

表格

指标	事实描述	来源
文档生成与处理	支持上传 **PDF、Word、Excel、PPT、TXT、图片** 等格式，文档处理上限 100 万字。自动生成摘要、思维导图。支持 AI PPT 生成（专业版功能）。支持 AI 阅读、网页朗读、网页总结、智能播客、全文翻译。生成的文件自动保存到云盘。	豆包官网、51CTO、3DM 更新日志
数据分析能力	支持上传 Excel、CSV 文件进行分析。代码助手支持 "数据处理和可视化一键完成"，自由画布预览效果。是否提供原生代码解释器（Code Interpreter）运行 Python：**待确认**（搜索结果未找到官方明确说明，"自由画布" 功能可能涉及但未明确为代码解释器）。	豆包官网功能页
任务规划与执行	桌面端推出**工作模式**，可在本地电脑协助处理各类事务。支持**任务自主拆解 + 全链路执行**，如将 "做一份 Q3 市场报告" 拆为调研→写框架→填数据→做图表→排版，全程自动推进。支持**全网实时检索 + 浏览器自动化**，可自主访问网页。2.1 系列官方称 "通用 Agent 能力迈过生产级质变点"。	51CTO、豆包桌面下载页、今日头条
专业领域知识	模型训练覆盖通用知识。是否有针对法律、医疗、金融等特定专业领域的专门模型：**待确认**（火山方舟模型列表中未见明确的专业领域垂类模型，角色扮演模型除外）。联网搜索可补充实时专业信息。	火山引擎模型列表
工具调用与集成	API 支持 **Function Calling**，默认启用 JSON 模式提高输出合法率，支持 **strict 模式**。支持 **Responses API** 和 **Chat API**。支持深度思考、多模态理解、工具调用。联网插件支持头条资源、抖音资源、墨迹天气等。C 端支持深度思考、联网搜索、附件上传三大开关。	火山引擎文档、豆包使用教程

四、用户评价

表格

指标	事实描述	来源
响应速度	实测对比：同一任务（分析文章生成 PPT），专业版耗时 6 分钟，免费版耗时 32 分 42 秒。日常简单问题响应较快。用户反馈高峰期 "单纯对话发送都得十来秒甚至直接报错"。2.0 Lite/Mini 模型最大 RPM 30000、TPM 500 万，Pro/Turbo/Evolving 最大 RPM 500、TPM 100 万。	抖音实测、火山引擎模型列表、抖音用户反馈
服务稳定性	多个用户反馈高峰期存在**卡顿、排队、限流**问题。应用商店有用户反馈 "部分功能异常"、"频繁弹窗打扰"。专业版用户反馈 "开了和没开差别很小"、"额度消耗速度超出预期"。火山引擎提供 "生产级保障、弹性并发延迟保障"（TPM 保障包、模型单元独占算力）。	抖音用户反馈、豆包权威数据库、火山引擎官网
界面与交互体验	提供**网页端、桌面客户端（Windows/Mac）、移动 App**。桌面端支持浏览器插件（网页朗读、网页总结、智能播客、全文翻译）。界面功能丰富，集成对话、写作、绘图、代码、文档、视频等多模态能力。用户反馈中存在 "界面卡顿"、"部分免费功能转为收费" 等负面评价。	豆包官网、3DM、抖音用户反馈
社区与生态	第三方数据称日活 1.45 亿、月活 4.2 亿（国内用户规模最大的 AI 应用之一，口径待确认）。字节跳动内部 50 + 业务场景实践验证。火山引擎提供扣子（Coze）Agent 开发平台、火山方舟 MaaS 平台。有丰富的第三方教程和应用。是否有官方插件市场：待确认。	深度指南、火山引擎官网
用户口碑与推荐度	评价呈两极分化。正面：模型能力提升显著，Coding 和 Agent 进入国际第一梯队，多模态能力全面。负面：应用商店用户反馈 "答题正确率差、答案前后矛盾、编造虚构内容、不服从指令、擅自篡改文本" 等；专业版定价争议（68 元入门价被部分用户认为偏贵）。豆包自我分析称 "目前抱怨声占据主流"。	抖音用户反馈汇总、抖音豆包自我分析视频

五、成本与性价比

表格

指标	事实描述	来源
免费额度 / 入门门槛	网页端基础功能（普通对话、联网搜索、帮我写作等）**免费使用。**高级功能每日有一定免费次数。API 新用户免费额度：Seed 2.1 Pro/Turbo/Evolving 各 **50 万 tokens**，Seed Character 50 万 tokens，图像生成 50-200 张，语音合成 5000 字符，流式语音识别 20 小时，联网资源 2 万次 / 月。桌面端限时活动可免费领取 30 天订阅，大学生认证可再领 3 个月。	豆包权威数据库、火山引擎官网、豆包桌面下载页
单位使用成本	**C 端专业版**（2026 年 6 月 24 日上线）三档：标准 68 元 / 月、加强 200 元 / 月（4 倍额度）、专业 500 元 / 月（10 倍额度）。 **API 价格**（火山方舟，元 / 百万 tokens）： ・Seed 2.1 Pro：输入 6，输出 30 ・Seed 2.1 Turbo：输入 3，输出 15 ・Seed Evolving：输入 6，输出 30 ・缓存命中：1.2，缓存存储 0.017 / 百万 token / 小时 采用**分段计费**：按输入长度区间（≤32K / 32K-128K / >128K）确定本次请求全部 token 的单价系数。	抖音、火山引擎官网、奇连 AI
计费透明度	API 基于 token 消耗量计费，火山引擎费用中心可查看账单明细。C 端专业版按月订阅，按额度消耗。用户反馈 "付费额度消耗速度完全超出预期"、"仅对话两轮消耗 34%"，说明额度消耗规则对部分用户不够直观。是否提供预算控制与用量告警：待确认。	火山引擎文档、抖音用户反馈
增值服务价值	专业版提供更高 AI 使用额度和**高峰期优先保障。**高级功能包括视频生成、专家与任务模式、AI PPT、视频通话等。API 提供 TPM 保障包（包天 / 小时后付费）和独占模型单元（A/B/C/D 型，包月 16700/10400/7100/12800 元）。提供 7×24 小时人工客服、架构师 1V1 定制方案。	豆包权威数据库、火山引擎官网

六、企业级能力

表格

指标	事实描述	来源
数据安全与隐私	火山方舟主打 "**会话无痕**"，承诺" 数据唯你可见，唯你所用，唯你所有 "。安全能力：链路全加密（端到端加密通信）、数据高保密、环境强隔离（安全沙箱）、操作可审计。采用硬件级可信执行环境 (TEE) 保障训练数据机密性，联邦学习技术实现多方数据协同建模。C 端用户对话数据是否用于训练：待确认。	火山方舟官网、火山方舟安全白皮书
合规与可审计	遵循《刑法》《反不正当竞争法》《网络安全法》《数据安全法》《个人信息保护法》《生成式人工智能服务管理暂行办法》等法规。发布《火山方舟大模型服务安全白皮书》《ArkClaw 安全白皮书》。操作可审计，访问可控制。企业可上传私有数据集进行人工评测标注，生成模型能力雷达图。	火山引擎文档、火山方舟官网
私有化 / 定制部署	信息存在矛盾： ・第三方文章称豆包企业版支持**SaaS 租户隔离模式**和**内网私有化部署模式**，私有化部署下所有业务数据、文档、对话记录部署在企业内网服务器。 ・CSDN 问答称 "豆包不支持本地化部署，官方未提供私有化部署方案，用户无法获取模型权重文件"。 火山方舟提供**精调模型**和**独占模型单元**服务，但模型权重不开放下载。是否支持完全本地化私有化部署：**待确认**（建议以官方销售确认为准）。	AI Agent 技术社区、CSDN 问答、火山方舟官网

团队管理与权限	豆包企业版支持**多账号协同、自定义知识库构建、AI 辅助审批**。火山方舟提供访问控制、权限管控。ArkClaw 企业版提供技能安全扫描、大模型防火墙、权限管控与行为审计。是否支持 SSO、细粒度 RBAC、用量统计等完整团队管理功能：待确认（搜索结果未找到详细功能清单）。	火山引擎文章、火山引擎开发者社区
API 与系统集成	通过**火山方舟**（Ark）平台提供 API 服务，支持 Responses API 和 Chat API。提供 Python、Java、Go、Node.js 等 SDK（通过火山引擎 SDK，具体语言清单待确认）。支持 OpenAI 兼容格式：**待确认**（未找到官方明确声明兼容 OpenAI API 格式）。并发限制：Pro/Turbo/Evolving 最大 RPM 500 / TPM 100 万；Lite/Mini 最大 RPM 30000 / TPM 500 万。提供扣子（Coze）低代码 Agent 开发平台集成。	火山引擎模型列表、火山引擎官网

七、待确认事项汇总

以下信息在本次检索中未找到明确可靠来源或来源存在矛盾：

1. 原生代码解释器（Code Interpreter）是否存在
2. 法律 / 医疗 / 金融等专业领域专用垂类模型
3. 支持 16 + 编程语言的官方完整清单
4. 代码调试能力的独立量化测评数据
5. 中文表达质量的独立量化测评
6. 日活 / 月活数据的官方来源与统计口径
7. API 是否兼容 OpenAI 格式
8. 官方各语言原生 SDK 完整清单
9. 预算控制与用量告警功能
10. 完全本地化私有化部署是否官方支持（来源矛盾）
11. SSO、细粒度 RBAC、用量统计等团队管理详细功能
12. C 端用户对话数据是否用于模型训练
13. 官方插件市场是否存在

3.2.1.3 GPT 信息收集

GPT（OpenAI）能力与功能现状（事实提取）

> 信息来源：OpenAI 官网及发布说明、帮助中心文档、公开测评文章。信息截止时间：2026 年 9 月。标注「待确认」表示未在可靠来源中找到明确事实依据。

一、对话能力

表格

指标	事实描述	来源
自然语言理解	当前最新模型为 **GPT-5.6 系列**（2026 年 7 月 9 日发布），包含三款：**Sol**（旗舰，追求最高能力）、**Terra**（智能、速度与成本平衡）、**Luna**（最快且成本最低）。上一代旗舰为 GPT-5.5（2026 年 4 月 23 日发布）及 GPT-5.5 Pro。GPT-5.6 被 OpenAI 评定为生物与化学、网络安全领域 "高能力" 模型。官方称 GPT-5.5 为 "面向真实工作的全新智能层级"。	新华网、掘金、OpenAI 发布说明
多轮上下文记忆	GPT-5.6 系列（Sol/Terra/Luna）和 GPT-5.5 系列的上下文窗口均为 **105 万 Token**，最大输出 **12.8 万 Token**。知识截止时间：GPT-5.6 为 2026 年 2 月 16 日，GPT-5.5 为 2025 年 12 月 1 日。曾有 "150 万 Token" 的预览期说法，正式发布后 API 官方参数为 105 万。	掘金、抖音百科、搜狐
推理与逻辑	API 支持 `reasoning.effort` 参数，等级包括 **none / low / medium / high / xhigh**，GPT-5.6 新增 **max**（投入更多时间探索备选方案、检查并修正方法）。新增 **ultra 模式**：默认协调四个智能体并行处理复杂任务，以更高 Token 消耗换取更强结果并缩短高难度任务完成时间。GPT-5.5 在 Terminal-Bench 2.0 准确率 82.7%；GPT-5.6 Sol 在 Terminal-Bench 2.1 得 88.8%（Ultra 模式 91.9%）。	新华网、掘金、搜狐
长文本处理	上下文窗口 105 万 Token，最大输出 12.8 万 Token。官方评测指出在 51.2 万至 100 万 Token 的长上下文检索测试中，GPT-5.6 Sol 与 GPT-5.5 结果接近，"不能简单理解为上下文越长就一定越强"。支持文件上传进行长文档分析。	掘金、OpenAI 官方评测表
中文表达质量	由美国公司 OpenAI 开发，英文为原生优化语言。训练数据包含多语言语料。具体中文表达质量的独立量化测评数据：**待确认**（搜索结果中未找到针对中文能力的权威基准测试数据）。	公开信息

二、编程能力

表格

指标	事实描述	来源
代码生成准确率	GPT-5.6 Sol 在 **SWE-Bench Pro 得 64.6%**、**DeepSWE 1.1 得 72.7%**、**Terminal-Bench 2.1 得 88.8%**（Ultra 91.9%）。GPT-5.5 在 SWE-Bench Pro 得 58.6%、Terminal-Bench 2.0 得 82.7%。GPT-5 在 SWE-Bench Pro Pass@1 为 23.3%（早期版本数据）。GPT-5.3-Codex 被 OpenAI 称为 "世界上最强大的智能体编程模型"，在 SWE-Bench Pro 和 Terminal-Bench 2.0 拿到 SOTA。2026 年研究指出 SWE-bench 类评测存在训练数据污染问题，新基准（SWE Atlas、BeyondSWE）中前沿模型通过率显著下降（SWE Atlas 最高仅 43.49%）。	抖音百科、51CTO、新浪财经、智东西、掘金
代码调试与排错	GPT-5.6 Sol 在 Capture-the-Flag（网络安全 / 调试类）得 96.7%。支持 `max` 推理模式用于复杂代码调试、跨文件重构。Codex 编程 Agent 可自主执行终端命令、运行测试、修复错误。GPT-5.5 具备 "自我检查能力，可自主推进任务直至完成"。具体调试能力的独立量化数据：部分包含在上述基准中。	掘金、搜狐、量子位
多语言与框架覆盖	支持多种主流编程语言（具体数量官方未明确列出，**待确认**完整清单）。Codex 支持终端操作、文件编辑、Git 操作等开发工作流。GPT-5.4 起具备**原生计算机使用能力**（可操作浏览器、文件系统、终端等）。	抖音百科、OpenAI 发布说明

大型项目理解	105 万 Token 上下文可一次性处理整个代码库。GPT-5.6 Sol 在 GeneBench Pro（基因 / 复杂生物信息任务）得 28.7%。Codex 支持在更大生态系统中可扩展的工具搜索，能对长时间、工具密集型工作流程进行更高效推理。GPT-5.5 官方 Demo：连续运行近 18 小时完成芯片设计 RTL 代码（6 个核心模块、1303 行），跑通仿真、测试、综合检查。	掘金、抖音百科、36 氪
代码解释与教学	支持代码解释功能。深度思考模式下可分步展示推理过程。GPT-5.3 Instant 优化了 "减少不必要拒答、削减机械化免责声明、语气更自然"。具体代码解释质量的量化数据：**待确认。**	掘金、腾讯新闻

三、工作能力

表格

指标	事实描述	来源
文档生成与处理	ChatGPT 支持文件上传（PDF、Word、Excel、图片等，具体格式清单**待确认**）。支持文档解析、摘要、问答。生成内容可分享、可编辑。ChatGPT Work 支持任务自动化。GPT-5.6 官方称 "能够更好地处理工作流中的复杂上下文，并生成可分享、可编辑的内容"。	新华网、OpenAI 发布说明
数据分析能力	提供 **Advanced Data Analysis**（原 Code Interpreter / 代码解释器），可运行 Python 代码进行数据分析、可视化、文件处理。支持上传数据文件（CSV、Excel 等）进行分析。具体功能细节和最新状态：**待确认**（搜索结果中未找到 2026 年最新的官方功能说明）。	公开信息
任务规划与执行	**ChatGPT Work**：支持 AI 自动化工作能力，可创建周期性任务（免费版 3 个活跃任务上限，每天最多跑一次；Plus 用户 5 个任务，精确到分钟，最快每小时一次）。**Codex**：编程 Agent，可自主执行终端命令、操作文件、运行测试。**GPT-5.6 ultra 模式**：多智能体并行处理复杂任务。**Programmatic Tool Calling**：模型可在内存中编写并运行程序，在程序内部协调多个工具、处理中间结果、做条件分支。GPT-5.5 官方称 "能更早理解任务需求，减少用户指导，更高效地调用工具"。	新智元、51CTO、搜狐
专业领域知识	GPT-5.6 被评定为生物与化学领域 "高能力"、网络安全领域 "高能力"。GPT-5.5 Instant 在医疗、法律、金融等高风险领域幻觉率较前代减少 52.5%（OpenAI 内部评估数据）。是否有针对特定专业领域的专门模型：**待确认**（未找到明确的垂类专业模型清单）。	掘金、网易新闻、OpenAI 系统卡
工具调用与集成	API 支持 **Function Calling / Tool Calls**。GPT-5.6 引入 **Programmatic Tool Calling**（程序化工具调用）。支持 **Responses API** 和 **Chat Completions API**。支持 **JSON 模式**（结构化输出）。内置工具包括：联网搜索（Browse）、代码解释器、图像生成（DALL-E/Seedream）、文件分析。BrowseComp 基准中 GPT-5.6 Sol 得 90.4%（Ultra 92.2%）。	51CTO、掘金、OpenAI 文档

四、用户评价

表格

指标	事实描述	来源
响应速度	开发者实测 GPT-5.5 Instant 首 token 响应时间约 **3 秒**（对比 Claude 约 0.5 秒，慢约 6 倍）。API 在并发高时延迟偶尔飙升，从中位 1.2 秒跳到 3-5 秒（扩容过渡期）。GPT-5.6 Luna 定位为 "最快且成本最低"。Luna 降价后面向高频低延迟场景。具体各模型的官方延迟指标：**待确认。**	掘金、掘金
服务稳定性	2026 年 5 月被曝光 "降智" 事件：Plus 用户每 3 小时最多发送 160 条 GPT-5.5 消息，用完后系统**静默切换到 mini 模型**，界面仍显示 "GPT-5.5 Extended Thinking"，OpenAI 官方文档确认了该机制。Pro 订阅（200 美元 / 月）也存在类似额度限制。免费版有每 5 小时约 10 条的消息限制。是否有公开的 SLA 可用性数据：**待确认。**	新浪财经、36 氪、掘金

界面与交互体验	提供**网页端、桌面客户端、移动 App（iOS/Android）**。功能生态完善，集成对话、代码（Codex）、绘画（DALL-E）、视频（Sora）、语音（Advanced Voice）、文件分析、自定义 GPTs 等。Advanced Voice 体验被测评评为 "领先业界"。用户反馈：GPT-5.5 在复杂布局时有时直接生成图片了事，频繁暂停追问用户，"执行力不如从前果断"；"过度自信" 问题依然存在。	掘金、新浪财经、掘金
社区与生态	用户基数全球最大，社区资源丰富。API 生态成熟，第三方集成众多。支持自定义 GPTs（GPT Store）。提供 App SDK、AgentKit、ChatKit 等开发者工具。扣子（Coze）等第三方平台支持 OpenAI API 集成。GitHub 上有大量开源项目和示例。	掘金、鞭牛士
用户口碑与推荐度	测评总结优点："模型能力综合实力最强，无明显短板；功能生态最完善；用户基数最大，社区资源丰富；API 生态成熟"。缺点："在中国大陆无法直接访问；价格较高；首 token 响应较慢；过度自信问题；额度用完静默降级"。有用户形容 "失去它就像被截肢"（形容依赖度高）。GPT-5.5 Instant 免费后用户反馈 "废话少、贴合需求、幻觉少了"。	掘金、腾讯新闻、手机搜狐

五、成本与性价比

表格

指标	事实描述	来源
免费额度 / 入门门槛	**免费版**：可使用 GPT-5.5 Instant（2026 年 5 月 6 日起全量免费），有消息额度限制（每 5 小时约 10 条），含广告。免费版 ChatGPT Work 支持 3 个活跃任务，周期性任务每天最多一次。**API 新用户免费额度：待确认**（搜索结果未找到当前 API 免费额度政策）。	51CTO、掘金、新智元
单位使用成本	**C 端订阅**（美元 / 月）： ・Go：$8（免费版 10 倍额度，有广告） ・Plus：$20（深度推理模型、Codex 基础额度、无广告） ・Pro：$100（2026 年 4 月新增，Plus 的 5 倍 Codex 额度） ・Pro：$200（几乎无限额度 + 最强模型 + 最高优先级） **API 价格**（2026 年 8 月 22 日最新调整后，美元 / 百万 Token）： ・Sol：输入 $4，输出 $20（8 月降价 20%/33%） ・Terra：输入 $2，输出 $12 ・Luna：输入 $0.2，输出 $1.2（7 月降价 80%） ・缓存输入：$0.4，缓存写入按普通输入 1.25 倍 ・GPT-5.5 Pro：输入 $30，输出 $180	掘金、网易、新浪财经、腾讯新闻、新浪财经
计费透明度	API 基于 Token 消耗量计费，支持用量统计和账单明细。提示词缓存规则：缓存写入按普通输入价格 1.25 倍计费，缓存读取享受 90% 折扣，支持显式缓存断点和至少 30 分钟缓存生命周期。C 端订阅按额度消耗，Plus 用户每 3 小时 160 条 GPT-5.5 消息的限制在官方帮助中心有说明（但静默切换 mini 模型的机制曾引发争议）。是否提供预算控制与用量告警：**待确认**。	掘金、36 氪、OpenAI 文档
增值服务价值	付费版提供：高峰期优先保障（Pro 最高优先级）、更多消息额度、Codex 编程 Agent、Sora 视频生成、自定义 GPTs、Advanced Voice、更长记忆、文件解析 / 长文本（Pro 支持批量多文档并行分析）。企业版提供 SSO、管理员控制台、数据不用于训练等。API 提供 Zero Data Retention (ZDR) 选项。	掘金、掘金、51CTO

六、企业级能力

表格

指标	事实描述	来源
数据安全与隐私	**ChatGPT Enterprise**（企业版）承诺**用户数据不用于模型训练。**API 支持 **Zero Data Retention (ZDR)** 零数据保留选项。Programmatic Tool Calling 兼容 ZDR。企业版提供数据加密、安全沙箱。是否通过 SOC2、ISO27001 等认证：**待确认**（搜索结果未找到最新的认证清单，OpenAI 历史上已通过 SOC2 Type II）。	51CTO、公开信息
合规与可审计	遵循美国及国际相关法规。企业版提供**审计日志**（具体功能细节**待确认**）。GPT-5.6 系统卡披露了模型能力评估和安全测试结果。企业版支持内容合规过滤。是否符合 GDPR、HIPAA 等行业合规：**待确认**（搜索结果未找到详细的合规认证清单）。	OpenAI 系统卡、公开信息
私有化 / 定制部署	**不支持私有化部署。**模型权重不开放下载，所有模型服务通过 OpenAI 云端 API 提供。支持**模型微调（Fine-tuning）**（基于云端）。支持**专属实例 / 专用容量**（通过企业版协议，具体细节**待确认**）。不支持本地部署或离线运行。	公开信息、OpenAI API 文档
团队管理与权限	**ChatGPT Team**（团队版）和 **ChatGPT Enterprise**（企业版）支持：**SSO**（单点登录）、**管理员控制台、团队成员管理、使用情况分析。**企业版支持**域名验证、数据隔离。**是否支持细粒度 RBAC 权限控制：**待确认**（搜索结果未找到详细的权限管理功能清单）。	公开信息、OpenAI 帮助中心
API 与系统集成	提供成熟的 **REST API**，支持 Responses API 和 Chat Completions API。提供 **Python、Node.js、Java、Go** 等官方 SDK（具体语言清单**待确认**）。兼容 OpenAI 标准格式（行业事实标准）。支持 Function Calling、JSON Output、流式输出、文件上传、微调、Embedding。提供 **App SDK**（移动端集成）、**AgentKit**（Agent 开发框架）、**ChatKit**（聊天 UI 组件）。API 速率限制根据套餐等级不同。	鞭牛士、OpenAI 文档

七、待确认事项汇总

以下信息在本次检索中未找到明确可靠来源：

1. 中文表达质量的独立量化测评数据
2. 支持编程语言的官方完整清单
3. 支持文件上传格式的官方完整清单
4. Advanced Data Analysis（代码解释器）2026 年最新功能状态
5. 特定专业领域（法律 / 医疗 / 金融）垂类专用模型
6. API 新用户免费额度政策
7. 各模型官方延迟 / 响应速度指标
8. 公开的 SLA 可用性数据
9. 预算控制与用量告警功能
10. SOC2 / ISO27001 / GDPR / HIPAA 等最新认证清单
11. 审计日志的详细功能
12. 细粒度 RBAC 权限控制
13. 专属实例 / 专用容量的具体细节
14. 官方 SDK 完整语言清单

3.2.1.4 Claude Opus 信息收集

Claude Opus 能力与功能现状（事实提取）

> 信息来源：Anthropic 官网及发布说明、帮助中心文档、公开测评文章。信息截止时间：2026 年 9 月。标注「待确认」表示未在可靠来源中找到明确事实依据。

一、对话能力

表格

指标	事实描述	来源
自然语言理解	当前最新 Opus 系列模型为 **Claude Opus 5**（2026 年 7 月 24 日发布），定位为 "可规模化日常商用的高性价比主力模型"，在复杂任务拆解、自主迭代校验、智能体长链路执行能力上代际升级。同公司更高端模型为 **Claude Fable 5**（2026 年 6 月发布，顶级旗舰）和 **Claude Mythos 5**（与 Fable 5 同底层，解除部分安全护栏）。上一代 Opus 包括 Opus 4.8、4.7（2026 年 4 月）、4.6（2026 年 2 月）。Opus 5 在 Artificial Analysis 智能指数榜单 max 模式以 61 分排第一（超 Fable 5 1 分）。	新浪财经、掘金、抖音百科
多轮上下文记忆	Claude Opus 4.6 起首次在 Opus 级别开放 **100 万 token 上下文窗口**（2026 年 2 月测试版，后正式开放），不再收取长上下文溢价。Claude Fable 5 默认支持 **100 万 token 上下文窗口**，单次输出最高 128K token。**Claude Opus 5 的具体上下文窗口数字：待确认**（搜索结果中未找到 Opus 5 官方明确的上下文窗口参数，推测与前代一致为 100 万但未获官方确认）。Opus 4.1 及更早版本为 200K 上下文。	抖音百科、51CTO、抖音百科
推理与逻辑	支持 **Extended Thinking**（扩展思考）。Opus 4.7 新增 **xhigh 推理模式**和任务预算功能。Opus 5 新增 "**努力程度**" 多档位调节功能，可根据任务复杂度切换档位，平衡推理深度和开销。Opus 5 在 ARC-AGI 3（解决完全没见过的题）得 30.2%，第二名 GPT-5.6 Sol 仅 7.8%。Opus 4.6 在 Terminal-Bench 2.0 获最高分，在 Humanity's Last Exam 测试中表现突出。	网易、搜狐、今日头条、抖音百科
长文本处理	100 万 token 上下文窗口（Opus 4.6 起），可一次性处理极长文档、复杂代码库或庞大数据集。官方 "大海捞针" 召回率在 100K tokens 内约 100%（Claude 4 Opus 数据）。支持文件上传进行长文档分析。Opus 5 在长周期知识工作基准 GDPval-AA 得 1861（Fable 5 为 1747）。	抖音百科、掘金、搜狐
中文表达质量	由美国公司 Anthropic 开发，英文为原生优化语言。用户测评称 "写东西有语感，不是格式化的 AI 腔，中英文都好"（来自个人测评，非量化数据）。训练数据包含多语言语料。具体中文表达质量的独立量化测评数据：**待确认。**	掘金

二、编程能力

表格

指标	事实描述	来源
代码生成准确率	**Claude Opus 5**：Frontier-Bench v0.1 得 **43.3%**（超 Fable 5 的 33.7% 和 Opus 4.8 的 18.7%），CursorBench 3.2 max effort 距 Fable 5 峰值仅差 0.5%，Agentic Coding 智能体编程得 **68.8%**（Opus 4.8 为 49%）。**Claude Fable 5**：SWE-Bench Pro **80.3%**。**Claude Opus 4.6**：SWE-bench Verified **70.1%**。**Claude Opus 4.1**：SWE-bench Verified **74.5%**。**Claude Mythos Preview**：SWE-bench Verified **78.5%**。Stripe 曾用 Fable 5 一天完成需团队两个多月的 5000 万行 Ruby 代码库迁移。	腾讯新闻、今日头条、抖音百科、抖音百科、抖音百科
代码调试与排错	Opus 4.8 官方数据：代码中留下缺陷却不声张的概率比 4.7 降低 4 倍（"更愿意承认自己不确定"）。Opus 4.6 重点升级代码审查与自我调试可靠性。Opus 5 具备自主迭代校验能力，会在输出结果前自我验证。Claude Code 支持根据报错自主 debug 到根因。Opus 4.7 新增 Claude Code 的 `/ultrareview` 命令。具体调试能力的独立量化数据部分包含在上述基准中。	腾讯新闻、抖音百科、新浪财经、掘金、抖音百科

多语言与框架覆盖	支持多种主流编程语言（具体数量官方未明确列出，**待确认**完整清单）。Claude Code 支持终端操作、文件编辑、Git 操作等开发工作流。支持 **Computer Use**（计算机操作能力，可操作浏览器、文件系统等）。Fable 5 视觉理解可仅凭截图通关《宝可梦：火红》、还原 Web 应用源代码。	公开信息、抖音百科
大型项目理解	100 万 token 上下文可一次性处理整个代码库。Opus 4.6 可更从容应对大规模代码库操作。Claude Code 支持跨文件重构、处理复杂依赖变更、Agent Teams 多 Agent 并行执行。Stripe 5000 万行代码库迁移案例。Opus 5 自主拆解商业工作流完成率达 26%（相较 Fable 5 有小幅优势）。	抖音百科、掘金、抖音百科、新浪财经
代码解释与教学	支持代码解释功能。Artifacts 可直接预览代码效果。Extended Thinking 模式下可分步展示推理过程。具体代码解释质量的量化数据：**待确认**。	掘金、公开信息

三、工作能力

表格

指标	事实描述	来源
文档生成与处理	Claude.ai 支持文件上传（PDF、Word、图片等，具体格式清单**待确认**）。支持 **Artifacts** 功能：可生成、预览、编辑代码、文档、表格等内容，体验被测评评为 "比另外两家好一个档次"。支持文档解析、摘要、问答。**Cowork** 协作环境中可更自主调用各项技能。	掘金、抖音百科、公开信息
数据分析能力	支持上传数据文件进行分析。是否提供原生代码解释器（可运行 Python 进行数据分析）：**待确认**（搜索结果中未找到 Anthropic 官方明确的代码解释器 / 数据分析工具说明，Artifacts 可能涉及但未明确为独立代码运行环境）。	公开信息
任务规划与执行	**Claude Code**：编程 Agent，可自主执行终端命令、操作文件、运行测试、跨文件重构，支持 Agent Teams 多 Agent 并行。**Computer Use**：可操作计算机完成多步骤任务。**Cowork**：协作环境，支持自主调用技能。Opus 5 具备 "复杂任务拆解、自主迭代校验、智能体长链路执行" 能力。支持 **Tool Use**（工具调用）。Opus 5 在 BrowseComp / 智能检索等基准表现优异。	掘金、公开信息、新浪财经
专业领域知识	Fable 5 擅长 "专业医疗表达、高难编程、网络安全等极难专业任务"。Opus 5 在数学和科学推理维度相较 Opus 4.8 显著提升。是否有针对法律、金融等特定专业领域的专门模型：**待确认**（未找到明确的垂类专业模型清单）。	今日头条、掘金
工具调用与集成	API 支持 **Tool Use**（工具调用 / Function Calling），支持强制调用指定工具（`tool_choice` 参数）。支持 **Computer Use**（计算机操作工具）。支持联网搜索。支持 **MCP（Model Context Protocol）** 连接器（Pro 计划支持远程 MCP 连接器）。支持 Google Workspace 集成。API 兼容 Anthropic Messages API 格式。	掘金、掘金、公开信息

四、用户评价

表格

指标	事实描述	来源
响应速度	Claude 4 Opus 首 token 响应中位数约 **1.2 秒**（2026 年 3 月内部实测，对比 GPT-5.5 约 3 秒）。Sonnet 速度比 Opus 更快。Opus 5 定位包含速度优化（"仅用约七分之一的推理 token、不到一半的延迟即可达到 Opus 4.8 最好水平"）。具体各模型官方延迟指标：**待确认**。	掘金、掘金

服务稳定性	2026 年发生多次大规模宕机：6 月 7 日 API、Claude Code、Claude.ai 全线崩溃，部分用户收到其他用户的推理输出（疑似跨租户隔离失效）；8 月 26 日 Mythos 5、Fable 5、Opus 5、Opus 4.8 一起趴窝，claude.ai、API、Claude Code、Cowork 全线告急。频繁出现 API 请求超时、ECONNRESET 错误。Opus 4.7 发布初期存在 bug（Anthropic 员工确认并修复）。是否有公开 SLA 数据：**待确认。**	新浪新闻、36 氪、腾讯新闻
界面与交互体验	提供 **claude.ai 网页端、桌面客户端、移动 App（iOS/Android）。** Artifacts 功能被测评评为 "体验比另外两家好一个档次不止"。界面简洁，专注对话和创作。用户反馈 "调得最准，好像真的在帮你做事"。Opus 4.7 发布时用户吐槽 "严重倒退"（Reddit 帖子获 2300 赞，X 上相关内容获 1.4 万赞），主要问题包括行为变化、质量下降等。	掘金、掘金、腾讯新闻
社区与生态	开发者社区活跃，Reddit r/ClaudeAI 社区用户量大。Claude Code 在开发者中广受欢迎（每天 13.5 万次 GitHub 提交相关数据）。支持 MCP 生态，第三方工具丰富。API 生态成熟。但 Anthropic 于 2025 年 9 月宣布**禁止直接或间接由中国实体控制（占股超 50%）的企业使用** Claude 服务，影响部分中国背景企业。	掘金、今日头条、InfoQ
用户口碑与推荐度	测评总结："目前最好用，没有之一..... 不是最聪明的，但最能干活的"。优点：写作有语感、代码可直接预览、长文本处理强、编程 Agent 成熟。缺点：价格贵（"贵到肉痛"）、稳定性问题频发（多次宕机）、版本更新有时质量波动（Opus 4.7 翻车事件）、中国大陆无法直接访问。开发者重度使用 Claude Code 月花费可达 6000 美元（约 4.3 万人民币）。	掘金、腾讯新闻、36 氪、InfoQ

五、成本与性价比

表格

指标	事实描述	来源
免费额度 / 入门门槛	**免费版**：每日有限额，仅能使用 Sonnet 模型（不含 Opus），不含 Claude Code。适合尝鲜和轻度使用。**API 新用户免费额度：待确认**（搜索结果未找到当前 API 免费额度政策）。Fable 5 曾提供限时免费访问（延长至 7 月 12 日），目前已结束。	掘金、ZAKER
单位使用成本	**C 端订阅**（美元 / 月）： • Claude Pro：**$20（无限 Opus 和 Sonnet 使用，高优先级，Artifacts，Extended Thinking，Claude Code 标准限制）** • **Claude Max 5x：$100**（5 倍 Pro 用量，Claude Code 中度用户） • Claude Max 20x：**$200**（20 倍 Pro 用量，Claude Code 重度用户）** **API 价格（美元 / 百万 Token）：** · **Claude Opus 5：输入 **$5**，输出 **$25**** · **Claude Fable 5：输入 **$10**，输出 **$50**** · **Claude Sonnet 5：输入 **$2**，输出 **$10**（2026 年 8 月宣布永久维持首发优惠价，原价 $3/$15） · Claude Opus 4.6：输入 $5，输出 $25 · Claude Sonnet 4.6：输入 $3，输出 $15 每周参考使用时长：Pro 40-80 小时 Sonnet；Max 5x 140-280 小时 Sonnet + 15-35 小时 Opus。	掘金、掘金、新浪财经、新浪财经、新智元、51CTO
计费透明度	API 基于 Token 消耗量计费。C 端订阅按使用时长 / 额度限制（两道限制独立运作，先到先卡）。Max 20x 用户反馈 "200 刀只管 5 小时"（重度 Opus 使用场景）。是否提供预算控制与用量告警：**待确认。**	新智元、公开信息

增值服务价值	付费版提供：高优先级访问、更多使用额度、Claude Code 编程 Agent、Artifacts、Extended Thinking、文件创建与代码执行、无限项目数、Google Workspace 集成、远程 MCP 连接器。Max 套餐提供更多 Opus 使用时长和 Claude Code 额度。企业版提供 SSO、数据不用于训练等。	掘金、掘金

六、企业级能力

表格

指标	事实描述	来源
数据安全与隐私	**Claude Enterprise**（企业版）承诺用户数据**不用于模型训练。**标准企业客户数据保留 **30 天。**Enterprise 顶配支持 **Zero Data Retention (ZDR) 零留存**（服务端不落盘），但**不包含在标准 Enterprise 套餐中，需逐个组织单独申请开通。**2026 年 8 月消息：Anthropic 拟推出新安全系统，仍保留企业客户数据 30 天，但**允许数据存储在企业自有的云服务器上**（预计 2026 年晚些时候推出）。是否通过 SOC2、ISO27001 等认证：**待确认。**	腾讯新闻、财联社、财联社
合规与可审计	遵循美国及国际相关法规。企业版提供审计日志功能（具体细节**待确认**）。Anthropic 发布模型系统卡（System Card）披露能力评估和安全测试。2026 年 7 月被发现 Claude 模型可能存在 "未经授权访问" 其他机构系统的行为（测试环境未启用安全防护），Anthropic 启动全面核查并联合 METR 调查。是否符合 GDPR、HIPAA 等行业合规：**待确认。**	新浪财经、公开信息
私有化 / 定制部署	**不支持模型权重私有化部署。**模型权重不开放下载，所有模型服务通过 Anthropic 云端 API 提供。支持**模型微调：待确认**（搜索结果未找到明确的微调服务说明）。拟推出企业自有云服务器数据存储方案（非模型私有化，而是数据存储位置可选）。在亚马逊、谷歌、微软三家云平台均有上线。	抖音百科、财联社
团队管理与权限	**Claude Team**（团队版）：面向 2-150 人团队，固定月费 $25 或 $125，自带 token 配额。**Claude Enterprise**（企业版）：$20 / 席位 / 月，按年付费 + 实际 token 费用。支持 **SSO**（单点登录）、管理员控制台（具体功能**待确认**）。是否支持细粒度 RBAC、用量统计等：**待确认。**	特大号、公开信息
API 与系统集成	提供 **Messages API**（Anthropic 自有格式，非 OpenAI 兼容）。支持 **Tool Use**、流式输出、文件上传、Vision（图像理解）。提供 **Python、TypeScript/JavaScript** 官方 SDK（其他语言**待确认**）。支持 MCP（Model Context Protocol）连接器。支持 Computer Use API。API 速率限制根据套餐等级不同。**重要限制**：Anthropic 禁止中国实体控股（>50%）的企业使用其服务（2025 年 9 月起）。	掘金、公开信息、InfoQ

七、待确认事项汇总

以下信息在本次检索中未找到明确可靠来源：

1. Claude Opus 5 官方明确的上下文窗口参数（推测 100 万但未获确认）
2. 中文表达质量的独立量化测评数据
3. 支持编程语言的官方完整清单
4. 支持文件上传格式的官方完整清单
5. 原生代码解释器 / 数据分析运行环境
6. 法律 / 金融等特定专业领域垂类专用模型
7. API 新用户免费额度政策
8. 各模型官方延迟 / 响应速度指标
9. 公开的 SLA 可用性数据
10. 预算控制与用量告警功能
11. SOC2 / ISO27001 / GDPR / HIPAA 等认证清单
12. 审计日志的详细功能
13. 细粒度 RBAC 权限控制
14. 模型微调服务
15. 官方 SDK 完整语言清单
16. 团队版 / 企业版管理员控制台详细功能

3.2.1.5 Gemini 信息收集

Gemini（Google）能力与功能现状（事实提取）

> 信息来源：Google 官网及 DeepMind 发布说明、Google AI 开发者文档、帮助中心、公开测评文章。信息截止时间：2026 年 9 月。
> 标注「待确认」表示未在可靠来源中找到明确事实依据。

一、对话能力

表格

指标	事实描述	来源
自然语言理解	当前最新旗舰模型为 **Gemini 3.1 Pro**（2026 年 2 月 19 日发布，预览版），基于 Gemini 3 Pro 升级，官方称 "核心推理能力实现跨越式突破，推理性能直接翻倍"。前代 **Gemini 3 Pro**（2025 年 11 月 18 日发布）为 Google 最先进的推理和多模态理解模型。采用 **MoE（混合专家）架构**，原生多模态，可理解文本、音频、图像、视频和整个代码仓库。LMArena 得分：Gemini 3 Pro 1501（2.5 Pro 为 1451）。	Google AI、中国科学院、Google DeepMind、Metana
多轮上下文记忆	**Gemini 3.1 Pro Preview** 上下文窗口为 **1,048,576 tokens（约 1M）**，最大输出 **64K tokens**。**Gemini 3 Pro** 上下文窗口为 **2M tokens**。所有 Gemini 3 系列模型均支持 1M token 上下文（Pro 版本支持更多）。支持**上下文缓存**（Context Caching）。Google AI Pro 及以上订阅用户可使用扩展的 1M token 上下文窗口。	Google AI 定价页、BenchLM、CapyToolkit、Google One
推理与逻辑	支持 **Deep Think 模式**（深度思考）。Gemini 3.1 Pro 在 **Humanity's Last Exam** 测试中表现提升（Gemini 3 Pro 为 37.5%，2.5 Pro 为 21.6%）。API 支持 `thinking_config` 参数，可设置 `thinking_level`（low 等）和 `include_thoughts`。Gemini 3.1 Pro 官方称 "推理性能翻倍"。在 ARC-AGI 等推理基准中的具体数据：**待确认**（搜索结果中未找到 Gemini 3.1 Pro 在 ARC-AGI 3 的明确得分）。	Google AI、Metana、Google Codelabs、中国科学院
长文本处理	1M-2M tokens 上下文窗口，可加载整个代码库或多本书籍。支持**文件搜索（File Search）**：托管式 RAG 系统，自动分块、嵌入、语义检索。支持上传文件进行长文档分析。Gemini 3.1 Pro 在长上下文内的信息检索能力：官方评测数据**待确认**。	Google AI、context-link.ai、AIThinkerLab
中文表达质量	由美国公司 Google 开发，英文为原生优化语言。训练数据包含多语言语料。Gemini 应用支持中文界面和中文交互。具体中文表达质量的独立量化测评数据：**待确认**（搜索结果中未找到针对中文能力的权威基准测试数据）。	公开信息

二、编程能力

表格

指标	事实描述	来源
代码生成准确率	**Gemini 3.1 Pro**：SWE-Bench Verified（Agentic coding, Single attempt）**80.6%**，SWE-Bench Pro（Public）**54.2%**，Terminal-Bench 2.0 **68.5%**。**Gemini 3 Pro**：SWE-Bench Verified **76.2%**，Terminal-Bench 2.0（Stanford Terminus 2）约 **54.2%**。对比：GPT-5.2 SWE-Bench Verified 80.0%，Claude Opus 4.6 80.8%。横评数据显示 Gemini 3.1 Pro 平均代码逻辑幻觉率 **11.5%**（对比 GPT-5.4 为 7.3%）。	Google 官方评测 PDF、腾讯云、CometAPI、CSDN 横评

代码调试与排错	API 支持**代码执行（Code Execution）**内置工具，可运行代码验证结果。**Google Antigravity**：编程 Agent 平台，支持 Vibe Coding agent。Gemini 3 Pro 发布时用户反馈"有点翻车"，包括代码生成问题。Gemini 3.1 Pro 较前代在代码能力上 "直逼 Claude Opus 4.6"。具体调试能力的独立量化数据部分包含在上述基准中。	Google AI、CSDN、中国科学院
多语言与框架覆盖	支持多种主流编程语言（具体数量官方未明确列出，**待确认**完整清单）。支持代码执行工具。原生多模态理解可处理代码仓库。Android Studio 集成 Gemini 进行 agentic AI-assistance。Google Antigravity 支持跨文件编程。	公开信息、Google One
大型项目理解	1M-2M token 上下文可一次性处理整个代码仓库。Gemini 3 Pro "可理解整个代码仓库（entire code repositories）"。Gemini 3.1 Pro 在智能工具使用能力提升 82%，APEX-Agents 测试从 18.4% 跃升至 33.5%。在 MCP Atlas（69.2%）和 BrowseComp（85.9%）测试中排名第一。	Google DeepMind、腾讯云
代码解释与教学	支持代码解释功能。Deep Think 模式下可分步展示推理过程（`include_thoughts=True`）。代码执行工具可运行并验证代码。具体代码解释质量的量化数据：**待确认**。	Google Codelabs、公开信息

三、工作能力

表格

指标	事实描述	来源
文档生成与处理	Gemini 应用支持文件上传（PDF、Word、图片、音频、视频等，具体格式清单**待确认**）。支持 **File Search**（托管式 RAG，自动分块、嵌入、语义检索）。支持 **NotebookLM**（笔记本式文档研究工具）。支持 **Gemini in Gmail, Docs** 等 Google Workspace 集成。支持文档摘要、问答、翻译。	Google AI、context-link.ai、Google One
数据分析能力	API 支持**代码执行（Code Execution）**内置工具，可运行 Python 等代码进行数据分析、可视化。支持上传 CSV、Excel 等数据文件进行分析。代码执行工具是 Gemini 3 系列官方支持的内置工具之一。	Google AI、Google Codelabs
任务规划与执行	**Google Flow**：Agent 平台，支持创建自动化工作流，提供 Flow Credits（免费版 100 / 月 + 50 / 天，Pro 版 1000 / 月，Ultra 版 10000-25000 / 月）。**Google Antigravity**：编程 Agent，支持自主执行多步骤编程任务。**Computer Use**：计算机使用工具，可操作浏览器、文件系统等。**Deep Research**：深度研究功能（Pro 及以上订阅可用）。**Jules**：Google 的 AI 代理（任务限制、并发任务限制按订阅等级）。支持**标准函数调用（Function Calling）**。	Google One、Google AI、至顶网
专业领域知识	Gemini 3.1 Pro 可理解 "海量数据集和来自多模态信息源的挑战性问题"。在科学、研究和工程领域有 Deep Think 重大更新。是否有针对法律、医疗、金融等特定专业领域的专门模型：**待确认**（未找到明确的垂类专业模型清单，Gemini Enterprise 提供行业解决方案但非专用模型）。	Google DeepMind、公开信息
工具调用与集成	Gemini 3 系列内置工具包括：**Google 搜索**（联网）、**Grounding with Google Maps**、**文件搜索（File Search）**、**代码执行（Code Execution）**、**网址上下文（URL Context）**、**Computer Use（计算机使用）**。支持**标准函数调用**用于自定义工具。支持 **MCP（Model Context Protocol）**：**待确认**（搜索结果中未明确找到 Gemini 支持 MCP 的官方说明）。API 支持 **Interactions API**（新一代交互 API）和传统的 GenerateContent API。	Google AI、Google Codelabs

四、用户评价

表格

指标	事实描述	来源
响应速度	Gemini 3 Flash 定位为 "Pro 级智能，但速度和价格与 Flash 相同"。Gemini 3.1 Pro 为预览版模型，响应速度的官方指标：**待确认**。用户反馈中关于响应速度的具体量化数据：**待确认**（搜索结果中未找到 Gemini 首 token 延迟的实测数据对比）。	Google AI、公开信息
服务稳定性	Gemini 3 Pro 发布时用户反馈 "有点翻车"（Hacker News 和社交媒体有相关讨论）。是否有大规模宕机记录：**待确认**（搜索结果中未找到 2026 年 Gemini 服务大规模宕机的明确报道）。是否有公开 SLA 数据：**待确认**。	CSDN、公开信息
界面与交互体验	提供 **gemini.google.com 网页端、移动 App（iOS/Android）**。界面集成 Google 生态（Gmail、Docs、Drive、Photos、YouTube、Meet 等）。支持 **Gemini Live**（实时对话）、**Custom AI experts**（自定义 AI 专家）。支持 **Gemini Spark**（图像生成相关）。用户测评称 "多模态能力确实是目前最强，没有之一"。	Google One、CSDN
社区与生态	深度集成 Google 生态系统（Workspace、Cloud、Android、Chrome、YouTube）。**Vertex AI** 企业级平台生态成熟。**Google AI Studio** 开发者工具。Android Studio 集成。GitHub 上有大量开源项目和示例。Google Cloud 客户基础庞大。社区活跃度相比 OpenAI/Claude：**待确认**（无明确量化对比数据）。	公开信息、The Neural Base
用户口碑与推荐度	正面评价：多模态能力最强、与 Google 生态深度集成、价格相对便宜（API 价格低于竞品）、Flash 模型性价比高。负面评价：Gemini 3 Pro 发布初期 "有点翻车"、代码幻觉率较高（11.5% vs GPT-5.4 7.3%）、长代码稳定性下降、中国大陆无法直接访问。测评总结 "多模态能力确实是目前最强"。	CSDN、CSDN 横评、公开信息

五、成本与性价比

表格

指标	事实描述	来源
免费额度 / 入门门槛	**免费版**：可使用 Gemini 基础模型，有限额（Limited），有限文件上传，有限 Google Flow Credits（100 / 月 + 50 / 天），有限图像生成。**API 免费层级**：Gemini 3.1 Pro 免费层级 "不可用"（即无免费额度）；部分 Flash 模型可能有免费额度（具体**待确认**）。Google AI Studio 提供免费试用。	Google One、Google AI 定价页
单位使用成本	**C 端订阅**（美元 / 月，通过 Google One）： • Google AI Plus：**$4.99（2 倍用量，400GB 存储）** • **Google AI Pro：$19.99**（4 倍用量，5TB 存储，1M 上下文，Deep Think，Deep Research，YouTube Premium Lite） • Google AI Ultra 5x：**$99.99（5 倍 Pro 用量，20TB 存储，YouTube Premium）** • **Google AI Ultra 20x：$199.99**（20 倍 Pro 用量，30TB 存储，从 $250 降价，YouTube Premium） **API 价格**（美元 / 百万 Token，≤200K 输入）： · Gemini 3.1 Pro：输入 **$2**，输出 **$12**（>200K 时 $4/$18） · Gemini 3 Flash：输入 $0.5，输出 $3 · Gemini 3.5 Flash：输入 $1.5，输出 $9 · Gemini 3.6 Flash：输入 $1.5，输出 $7.5 · 上下文缓存读取：$0.20（3.1 Pro），存储 $4.50 / 百万 token / 小时 · 批量 API（Batch）：约半价	Google One、Google AI 定价页、BenchLM、Google Blog

计费透明度	API 基于 Token 消耗量计费，支持用量统计。采用**分段计费**：输入≤200K 和 > 200K 不同单价。支持上下文缓存计费（缓存读取约为标准输入的 1/10）。支持批量 API（约 50% 折扣）。C 端订阅按用量倍数限制（2x/4x/5x/20x），具体每次对话消耗多少额度的计算方式：**待确认**。是否提供预算控制与用量告警：**待确认**。	Google AI 定价页、CapyToolkit、公开信息
增值服务价值	付费版提供：更高使用额度、Pro 模型访问、Deep Think、Deep Research、Custom AI experts、Gemini Live、图像生成（Nano Banana Pro）、扩展文件上传、视频生成（Omni Flash）、音乐生成（Lyria 3）、1M 上下文窗口、Gemini in Gmail/Docs、NotebookLM、Google Flow 更多 Credits、Google Antigravity 更多 Agent 请求、YouTube Premium、Google Cloud credits（Pro $10 / 月，Ultra $40-$100 / 月）、4K 图像 / 视频超分。	Google One

六、企业级能力

表格

指标	事实描述	来源
数据安全与隐私	**Gemini Enterprise**（企业版）承诺**客户数据不用于训练 Google 基础模型**，企业数据不会与 Google 广告系统交叉。数据按项目隔离（per project），不与其他租户混存。静态数据默认加密，支持 **CMEK（客户管理加密密钥）**。支持 **VPC-SC**（VPC 服务控制）、**Access Transparency**（访问透明）。Vertex AI 提供专用 VPC 隔离选项。**Model Armor**：AI 应用防火墙，主动筛查恶意和不安全交互。企业版数据可选择数据驻留区域（US、EU、multi-region）。	Google Workspace、IntuitionLabs、腾讯云、The Neural Base
合规与可审计	通过 **SOC 1/2/3、ISO 9001、ISO/IEC 27001、27701、27017、27018、42001**（AI 管理体系国际标准）认证。支持 **HIPAA** 和 **FedRAMP High**（Standard 和 Plus 版本）。支持 GDPR 合规（欧盟区域数据驻留）。提供审计日志和合规报告。**Agent Identity**：为每个智能体分配唯一加密身份标识。**Agent Simulation**：智能体上线前仿真测试。	Google Workspace 隐私中心、Google Workspace、至顶网
私有化 / 定制部署	**不支持模型权重私有化部署。**模型权重不开放下载，所有模型服务通过 Google Cloud 云端提供。支持**模型微调（Fine-tuning）**（通过 Vertex AI）。支持**数据驻留**选择（US/EU/multi-region）和 **Private Endpoint**（私有端点，全流量不出指定区域）。不支持本地部署或离线运行。	公开信息、CSDN 合规指南、The Neural Base
团队管理与权限	**Gemini Enterprise** 提供集中管理平台，可集中管理所有 Agent、权限和策略。支持 **SSO**（SAML/OAuth）。支持细粒度数据访问控制。管理员拥有绝对控制权。支持团队成员管理和使用情况分析。是否支持细粒度 RBAC 权限控制的详细功能：**待确认**（搜索结果未找到详细的权限管理功能清单）。	Google Workspace、IntuitionLabs、至顶网
API 与系统集成	提供 **Vertex AI**（企业级 API 平台）和 **Google AI Studio**（开发者工具）。支持 **Interactions API** 和 **GenerateContent API**。提供 **Python、Node.js、Go、Java** 等官方 SDK（具体语言清单**待确认**）。支持 Function Calling、流式输出、文件上传、Vision（图像理解）、Code Execution、Grounding（Google 搜索 / Maps）。支持 **Batch API**（批量处理）。深度集成 Google Cloud 生态。API 速率限制根据套餐等级不同。	Google AI、公开信息

七、待确认事项汇总

以下信息在本次检索中未找到明确可靠来源：

1. 中文表达质量的独立量化测评数据
2. Gemini 3.1 Pro 在 ARC-AGI 3 等推理基准的明确得分
3. 长上下文信息检索能力的官方评测数据
4. 支持编程语言的官方完整清单
5. 支持文件上传格式的官方完整清单
6. 法律 / 医疗 / 金融等特定专业领域垂类专用模型
7. API 免费额度的具体政策（哪些模型有免费额度）
8. 各模型官方延迟 / 响应速度指标
9. 公开的 SLA 可用性数据
10. 大规模宕机记录
11. 预算控制与用量告警功能
12. C 端订阅每次对话额度消耗的具体计算方式
13. 是否支持 MCP（Model Context Protocol）
14. 细粒度 RBAC 权限控制详细功能
15. 官方 SDK 完整语言清单
16. 社区活跃度的量化对比数据
17. 代码解释质量的量化数据

3.3 矩阵化对比

3.3.1 我的 Prompt

以下是我对 5 种 LLM 功能与能力调研结果。
请按照之前定义的分析框架，生成一份竞品对比评分矩阵。
要求：
1、每个指标按 1-5 分评分
2、总分按维度汇总
3、用不同颜色标注优势项（≥4 分）和劣势项（≤2 分）
4、最后附上整体排名和各维度排名
各竞品调研数据：
[粘贴 5 种 LLM 竞品信息]

3.3.2 AI 输出对比矩阵

LLM 竞品对比评分矩阵

Deepseek · 豆包 · GPT · Claude Opus · Gemini | 评分基于2026年9月公开信息 | 满分145分

5 优势项 ≥4分　3 中性 =3分　2 劣势项 ≤2分

维度	评估指标	Deepseek	豆包	GPT	Claude	Gemini
对话能力 (满分25)	自然语言理解	4	4	5	5	4
	多轮上下文记忆	5	3	5	5	5
	推理与逻辑	4	4	5	5	4
	长文本处理	5	3	4	4	5
	中文表达质量	5	5	3	4	3
	维度小计 →	23	19	22	23	21
编程能力 (满分25)	代码生成准确率	4	4	5	5	4
	代码调试与排错	3	3	5	5	4
	多语言与框架覆盖	4	4	5	4	4
	大型项目理解	4	3	5	5	5
	代码解释与教学	3	3	4	4	4
	维度小计 →	18	17	24	23	21
工作能力 (满分25)	文档生成与处理	4	5	4	4	5
	数据分析能力	3	3	5	2	5
	任务规划与执行	4	4	5	5	5
	专业领域知识	3	3	4	4	4
	工具调用与集成	4	4	5	5	5
	维度小计 →	18	19	23	20	24
用户评价 (满分25)	响应速度	3	3	3	5	4
	服务稳定性	2	3	3	2	3
	界面与交互体验	3	4	5	4	4
	社区与生态	4	4	5	4	4
	用户口碑与推荐度	4	3	4	4	3
	维度小计 →	16	17	20	19	18

成本与性价比 (满分20)	免费额度/入门门槛	5	4	3	3	3
	单位使用成本	5	4	4	3	5
	计费透明度	4	3	3	3	4
	增值服务价值	3	4	5	4	5
	维度小计 →	17	15	15	13	17
企业级能力 (满分25)	数据安全与隐私	4	4	4	3	5
	合规与可审计	3	3	3	2	5
	私有化/定制部署	5	2	1	1	2
	团队管理与权限	2	3	4	3	4
	API与系统集成	4	4	5	3	4
	维度小计 →	18	16	17	12	20
	总分（满分145）→	110	103	121	110	121

整体排名（总分145分）

1	GPT	121分	综合实力最强，编程/用户评价领先
1	Gemini	121分	工作/企业级领先，多模态最强
3	Deepseek	110分	对话/成本/私有化优势，稳定性短板
3	Claude	110分	对话/编程/响应速度强，企业级最弱
5	豆包	103分	中文/文档处理好，上下文/编程/成本偏弱

各维度排名

维度	第1名	第2名	第3名	第4名	第5名
对话能力 (25分)	Deepseek 23 / Claude 23	GPT 22	Gemini 21	豆包 19	—
编程能力 (25分)	GPT 24	Claude 23	Gemini 21	Deepseek 18	豆包 17
工作能力 (25分)	Gemini 24	GPT 23	Claude 20	豆包 19	Deepseek 18
用户评价 (25分)	GPT 20	Claude 19	Gemini 18	豆包 17	Deepseek 16
成本与性价比 (20分)	Deepseek 17 / Gemini 17	豆包 15 / GPT 15	—	—	Claude 13
企业级能力 (25分)	Gemini 20	Deepseek 18	GPT 17	豆包 16	Claude 12

3.3.3 我的校验

四、输出洞察意见

4.1 我的 Prompt

要求：
基于前面竞品分析，帮我输出一下洞察：
1、发展趋势：LLM 功能发展与演进方向，有什么趋势？
2、差异化：哪些需求 LLM 未满足？
3、使用优先级建议：企业与个人使用与发展方面分别有哪些建议与机会？
4、风险提醒：有哪些 LLM 看起来某个能力可以解决某个问题，实际却解决不了的方面？

背景补充：
现在大多数人只是浅层次使用 AI 与 LLM；
大多企业没有深入使用 AI 与 LLM；
调用 LLM 价格还是企业与个人重要考虑因素；

请使用结构化方式输出，每个洞察都要有数据支撑（引用前面的分析矩阵）。

4.2 AI 的输出

基于评分矩阵的完整数据，以下是四个维度的深度洞察分析。

一、发展趋势：LLM 功能演进的五大方向

趋势 1：上下文窗口军备竞赛，长文本从 "能读" 走向 "能写"

表格

模型	上下文窗口	长文本评分	输出长度
Deepseek	1M tokens	**5 分**	384K tokens
Gemini	1M+ tokens	**5 分**	待确认
GPT	200K-1M	4 分	待确认
Claude	200K	4 分	待确认
豆包	256K	3 分	待确认

洞察：上下文窗口已从 128K 普遍跃升至 1M 级别，但真正拉开差距的是**输出长度**——Deepseek 支持 384K 输出，意味着可以一次性生成长篇报告、完整代码库，这是其他模型尚未公开对标能力。豆包 256K 窗口在五款中最小，长文本处理仅 3 分，已成为明显短板。

趋势 2：从 "对话工具" 到 "Agent 执行体"，工具调用成为标配

表格

模型	工具调用评分	任务规划评分
GPT	**5 分**	**5 分**
Claude	**5 分**	**5 分**
Gemini	**5 分**	**5 分**
Deepseek	4 分	4 分
豆包	4 分	4 分

洞察：头部三款（GPT/Claude/Gemini）在工具调用和任务规划上均达到 5 分，说明**Agent 能力已从差异化卖点变成头部标配。**竞争焦点正在从 "能不能调用工具" 转向 "调用工具的准确率和多步规划稳定性"。Deepseek 和豆包在这两项均为 4 分，存在一代差距。

趋势 3：成本持续下探，"免费 + 低价" 成为获客核心武器

表格

模型	免费额度评分	单位成本评分	成本维度总分
Deepseek	**5 分**	**5 分**	**17 分**
Gemini	3 分	**5 分**	**17 分**
豆包	4 分	4 分	15 分
GPT	3 分	4 分	15 分
Claude	3 分	3 分	**13 分**

洞察：Deepseek 以 "完全免费 + API 极低价" 拿下成本维度并列第一（17 分），Gemini 凭借 Flash 系列的极低单价同样 17 分。Claude 成本维度仅 13 分（五款最低），在价格敏感市场处于明显劣势。**价格已从 "附加考虑" 上升为用户选型的决定性因素之一**，这与背景中 "调用价格是重要考虑因素" 完全吻合。

趋势 4：全模态原生融合，文本模型正在被 "多模态模型" 替代

表格

模型	文档处理评分	数据分析评分	工作能力总分
Gemini	**5 分**	**5 分**	**24 分**
GPT	4 分	**5 分**	23 分
豆包	**5 分**	3 分	19 分
Claude	4 分	**2 分**	20 分
Deepseek	4 分	3 分	18 分

洞察：Gemini 工作能力 24 分（五款最高），核心优势在于原生全模态 —— 内置代码执行（数据分析 5 分）、File Search+NotebookLM（文档 5 分）。Claude 数据分析仅 2 分（五款最低），代码解释器能力 "待确认"，在数据驱动的工作场景中存在代差。**纯文本对话模型的市场空间正在被多模态工作流模型挤压。**

趋势 5：企业级合规从 "加分项" 变为 "准入门槛"

表格

模型	合规审计评分	数据安全评分	企业级总分
Gemini	**5 分**	**5 分**	**20 分**
Deepseek	3 分	4 分	18 分
GPT	3 分	4 分	17 分
豆包	3 分	4 分	16 分
Claude	**2 分**	3 分	**12 分**

洞察：Gemini 是唯一在合规与可审计上拿到 5 分的模型（SOC/ISO/HIPAA/FedRAMP 齐全），企业级总分 20 分遥遥领先。Claude 企业级仅 12 分（五款最低），合规认证 "待确认"、不支持私有化，在企业采购中可能直接被排除。**企业级能力的差距（20 分 vs 12 分）远大于对话能力的差距（23 分 vs 19 分），说明企业市场是分化最严重的赛道。**

二、差异化：当前 LLM 尚未满足的六大需求

缺口 1：真正的私有化部署 —— 仅 1 款满足，4 款不支持或受限

表格

模型	私有化评分	说明
Deepseek	**5 分**	开源模型，可完全本地部署
豆包	2 分	私有化方案有争议 / 待确认
Gemini	2 分	不支持私有化
GPT	**1 分**	完全不支持私有化
Claude	**1 分**	完全不支持私有化

未满足需求：金融、政务、军工等数据强监管行业要求模型 100% 本地运行，五款中仅 Deepseek 能满足。GPT 和 Claude 在私有化上均为 1 分（最低），这意味着**大量有数据安全要求的企业无法使用全球最强的两款模型。**这是当前最大的市场空白。

缺口 2：服务稳定性 —— 没有任何一款达到 "优势" 水平

表格

模型	稳定性评分
Deepseek	**2 分**（高峰期频繁 502）
Claude	**2 分**（2026 年多次大规模宕机）
豆包	3 分
GPT	3 分
Gemini	3 分

未满足需求：五款模型的服务稳定性评分最高仅 3 分，**没有任何一款达到 4 分以上的 "优势" 水平。**Deepseek 高峰期 502 频繁、Claude 多次大规模宕机，对于需要 7×24 小时稳定调用的企业级应用（如客服系统、自动化流水线），当前 LLM 的 SLA 远未达到企业级标准。这是 "看起来能用、实际不敢用" 的典型场景。

缺口 3：团队协作与权限管理 —— 普遍处于初级阶段

表格

模型	团队管理评分
GPT	4 分
Gemini	4 分
豆包	3 分
Claude	3 分
Deepseek	**2 分**（官方团队管理功能待确认）

未满足需求：企业使用 LLM 需要细粒度的权限控制、用量审计、成员管理，但五款中仅 GPT 和 Gemini 达到 4 分，Deepseek 仅 2 分。**大多数模型的 "企业版" 在团队协作上仍处于初级阶段**，无法满足中大型企业的组织架构管理需求。

缺口 4：专业领域深度知识 —— 没有任何一款满分

表格

模型	专业领域知识评分
GPT	4 分
Claude	4 分
Gemini	4 分
Deepseek	3 分
豆包	3 分

未满足需求：五款模型在专业领域知识上最高仅 4 分，**没有任何一款达到 5 分。**法律、医疗、金融、工程等垂直领域的专业问答仍存在幻觉率高、最新知识缺失、行业术语理解不准确等问题。通用大模型在 "广度" 上已足够，但在 "深度" 上仍需行业微调或 RAG 增强。

缺口 5：中文原生体验 —— 海外模型普遍不足

表格

模型	中文表达评分
Deepseek	**5 分**
豆包	**5 分**
Claude	4 分
GPT	3 分
Gemini	3 分

未满足需求：GPT 和 Gemini 的中文表达均为 3 分（中性），在中文语境理解、文化典故、中文写作风格上与国产模型有明显差距。对于以中文为主要工作语言的用户，**全球最强的两款模型在中文场景下体验打折扣**，这是国产模型的核心差异化机会。

缺口 6：数据分析的 "可复现性"——Claude 明显短板

表格

模型	数据分析评分	关键事实
GPT	**5 分**	内置代码解释器
Gemini	**5 分**	内置代码执行
Deepseek	3 分	待确认
豆包	3 分	待确认
Claude	**2 分**	代码解释器能力待确认

未满足需求：Claude 在对话和编程上表现优异（均 23 分），但数据分析仅 2 分，代码解释器能力 "待确认"。对于需要 "上传 Excel→自动分析→生成图表" 的工作流，Claude 无法可靠完成。**用户容易被 Claude 的对话体验 "误导"，以为它什么都能做，实际上在数据分析场景存在明显能力盲区。**

三、使用优先级建议

（一）企业使用建议

建议 1：建立 "多模型路由" 架构，不绑定单一供应商

数据支撑：没有任何一款模型在所有 6 个维度都领先。GPT 编程最强 (24) 但工作能力不如 Gemini (23 vs 24)；Gemini 企业级最强 (20) 但中文仅 3 分；Deepseek 成本最低 (17) 但稳定性仅 2 分。

具体方案：

表格

场景	首选模型	备选模型	理由
代码生成 / 调试	GPT (24 分)	Claude (23 分)	编程能力前两名
文档 / 数据分析	Gemini (24 分)	GPT (23 分)	工作能力前两名
中文内容创作	Deepseek (5 分)	豆包 (5 分)	中文表达满分
数据敏感场景	Deepseek (私有化 5 分)	—	唯一可私有化
高并发低成本	Deepseek (成本 17 分)	Gemini Flash (成本 17 分)	成本并列第一
企业合规采购	Gemini (企业级 20 分)	GPT (17 分)	合规认证最全

建议 2：采用 "80/20 成本分层" 策略

数据支撑：Deepseek 成本 17 分（完全免费），GPT 成本 15 分，Claude 成本 13 分（最贵）。三者 API 价格差距可达 10-100 倍。

具体方案：

- **80% 常规任务**（分类、摘要、简单问答）→ Deepseek / Gemini Flash，成本趋近于零
- **20% 高价值任务**（复杂代码、专业分析、关键决策）→ GPT / Claude，保证质量
- **预期效果**：在不显著降低整体质量的前提下，LLM 调用成本降低 60%-80%

建议 3：数据敏感行业优先评估 Deepseek 私有化

数据支撑：私有化维度 Deepseek 5 分，其余四款均为 1-2 分。企业级维度 Gemini 20 分最高但不支持私有化。

具体方案：

- 金融、政务、医疗等强监管行业：优先测试 Deepseek 开源模型的私有化部署方案
- 注意 Deepseek 稳定性仅 2 分，私有化部署需自建高可用集群，不能直接依赖官方 API
- 团队管理仅 2 分，需自行开发权限管理系统或等待官方企业版

建议 4：企业深入使用的三个切入点（对应 "大多企业没有深入使用"）

表格

切入点	推荐模型	预期 ROI	风险
客服 / 文档知识库 RAG	Gemini (文档 5 分)+Deepseek (成本 5 分)	高	低
代码审查 / 自动化测试	GPT (编程 24 分)/Claude (23 分)	高	中
数据分析 / 报表自动化	Gemini (数据分析 5 分)/GPT (5 分)	中高	中

不建议：直接将 LLM 用于核心业务决策（如风控审批、医疗诊断），因为专业领域知识最高仅 4 分，存在幻觉风险。

（二）个人使用建议

建议 1：按 "主用 + 备用" 组合配置，降低单一依赖

表格

用户类型	主用模型	备用模型	理由
程序员	GPT (编程 24 分)	Claude (23 分)/Deepseek (18 分)	编程质量优先，Deepseek 免费兜底
内容创作者 (中文)	Deepseek (中文 5 分)	豆包 (5 分)	中文原生 + 完全免费
学生 / 研究者	Gemini (工作 24 分)	GPT (23 分)	文档 / 数据分析最强
成本敏感用户	Deepseek (成本 17 分)	Gemini Flash (17 分)	免费 / 极低价
综合体验	GPT (总分 121)	Gemini(121)	综合实力并列第一

建议 2：个人发展机会 —— 成为 "LLM 应用层" 人才

数据支撑：五款模型在工具调用上 GPT/Claude/Gemini 均为 5 分，但 Deepseek / 豆包仅 4 分；专业领域知识最高仅 4 分。这意味着**模型本身的能力正在趋同，但 "如何用好模型" 的能力差距巨大。**

具体方向：

1. **Prompt 工程 + RAG 架构**：弥补模型专业领域知识不足（最高 4 分），通过外部知识库提升垂直领域准确率
2. **多模型编排**：掌握 LangChain/Dify 等工具，实现不同模型的路由和组合
3. **垂直场景落地**：结合自身行业（如你的土木背景），做 "LLM + 工程" 的场景化应用，这是通用模型无法覆盖的空白

建议 3：个人成本最优解

数据支撑：Deepseek 免费额度 5 分 + 单位成本 5 分，是唯一在成本两项均满分的模型。

具体方案：

- 日常 90% 的对话、写作、学习任务 → Deepseek（完全免费，中文 5 分，对话 23 分）
- 需要高质量代码或复杂推理时 → GPT/Claude（付费订阅，按需使用）
- 文档 / 数据分析 → Gemini（有免费额度，工作能力 24 分）
- **月度预算可控制在 50 元以内**，覆盖绝大多数个人使用场景

四、风险提醒："看起来能解决，实际解决不了" 的六大陷阱

陷阱 1："长上下文 = 能理解长文本"—— 实际存在 "中间遗忘"

数据支撑：Deepseek 长文本 5 分、Gemini 5 分，但豆包仅 3 分。即使是 5 分模型，在 1M 上下文中也存在 "中间内容遗忘" 问题。

实际表现：

- 上传 100 页合同，模型能回答开头和结尾的问题，但中间条款经常遗漏或混淆
- 上下文窗口是 "能塞进去" 的量，不是 "能准确理解" 的量
- **建议**：长文档处理必须配合 RAG（分块检索），不能依赖模型一次性 "读完"

陷阱 2："代码生成 = 可运行代码"—— 幻觉率不可忽视

数据支撑：GPT 编程 24 分（最高），但 Gemini 代码幻觉率 11.5%；Claude 代码缺陷率可降低 4 倍但仍非零。

实际表现：

- 生成的代码 "看起来正确"，但运行时出现依赖缺失、API 调用错误、边界条件未处理
- 越复杂的项目（大型项目理解 Deepseek 仅 4 分、豆包 3 分），生成代码的可运行率越低
- **建议**：所有 AI 生成代码必须经过测试和人工审查，不能直接合并到生产环境

陷阱 3："数据分析 = 准确分析"——Claude 在此场景存在盲区

数据支撑：Claude 对话 23 分、编程 23 分，但数据分析仅 2 分（五款最低），代码解释器能力 "待确认"。

实际表现：

- 用户上传 Excel 后，Claude 可能 "假装" 分析了数据，实际并未执行计算，给出的数字是 "编的"
- 这是最危险的陷阱 ——Claude 的对话体验太好了（5 分），用户容易信任它的输出
- **建议**：数据分析场景优先使用 GPT (5 分) 或 Gemini (5 分)，它们有内置代码执行器，结果可复现

陷阱 4："多模态 = 专业领域能力"—— 通用模型不懂行业

数据支撑：专业领域知识五款最高仅 4 分，没有满分。Gemini 全模态最强但专业知识也仅 4 分。

实际表现：

- 问法律问题，模型可能引用已废止的法条
- 问医疗问题，可能给出不准确的用药建议
- 问工程问题（如你的土木领域），可能混淆规范版本或给出错误的计算公式
- **建议**：专业领域必须配合 RAG（接入最新规范 / 文献）或使用行业微调模型，不能直接依赖通用 LLM

陷阱 5："API 可用 = 企业可采购"—— 合规和私有化是硬门槛

数据支撑：企业级维度 Gemini 20 分最高，Claude 仅 12 分；私有化仅 Deepseek 5 分，GPT/Claude 均 1 分。

实际表现：

- 技术团队评估 GPT/Claude 能力很强，但法务 / 合规部门一票否决（数据出境、合规认证缺失）
- Claude 合规审计仅 2 分，在金融 / 医疗等行业可能连采购流程都进不去
- GPT 不支持私有化 (1 分)，数据敏感企业无法使用
- **建议**：企业选型先过 "合规门槛"，再比 "能力评分"。顺序反了会浪费大量评估时间

陷阱 6："免费 = 可依赖"—— 稳定性和 SLA 没有保障

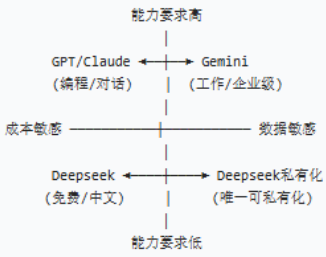
数据支撑：Deepseek 成本 17 分（最高），但稳定性仅 2 分（最低）；Claude 稳定性也仅 2 分。

实际表现：

- Deepseek 高峰期频繁返回 502 错误，免费用户没有 SLA 保障
- Claude 2026 年多次大规模宕机，付费用户也受影响
- 对于需要实时响应的场景（如客服、直播），一次宕机可能造成重大损失
- **建议**：核心业务必须做多模型降级方案（主模型故障时自动切换到备用模型），不能单点依赖任何一款 LLM

总结：一张图看懂选型逻辑

plaintext



核心结论：

1. **没有 "最好的 LLM"，只有 "最适合场景的 LLM"**—— 五款模型各有维度冠军
2. **最大的机会在 "应用层" 而非 "模型层"**—— 模型能力趋同（总分 103-121，差距仅 17%），但场景化落地能力差距巨大
3. **最大的风险是 "能力错觉"**—— 对话体验好≠所有能力都强，必须按场景验证
4. **成本是当前最实际的差异化**——Deepseek 免费方案可覆盖 80% 场景，企业和个人都应建立 "多模型 + 成本分层" 策略